


今回は、前回の講義ノートの **授業時間外学習** で指示したように 3Blue1BrownJapan による YouTube 動画を通じて**ディープラーニング（深層学習）**について「**予習**」してきていることを前提とした内容となります。

- **動画①**：[深層学習（ディープラーニング）Chapter1 基礎からの入門編、ニューラルネットワークの仕組み](#)
- **動画②**：[深層学習（ディープラーニング）Chapter2 深層学習の仕組み、勾配降下法](#)

ニューロン（生理学・神経科学編）

私たちの脳は「**ニューロン（Neuron）**」と呼ばれる神経細胞や、それを支持するグリア細胞などから構成される神経組織（Neural Tissue）から構成されています。ニューロンは電気信号や化学物質（神経伝達物質）の形で信号（情報）を受け取り、それを次のニューロンに伝える働きを持っています。人間の脳は約（ ）億個のニューロンから構成されており、それらが組織的に機能することで**記憶や思考、学習、感情といった複雑な「脳機能」が実現**されています。

個々のニューロンは、他の**複数のニューロンとつながっています**。このつながりの接続部分は、シナプス（Synapse）と呼ばれ、ニューロン同士が信号を受け渡す「接点」のような役割を持ちます。シナプスでは信号が一方方向にのみ伝達されるため、**ニューロン同士の接続は実質的に単方向**となります。このような接続によって形成される回路網は（ ） = Neural Network、神経回路網）と呼ばれています。このニューラルネットワークでは、視覚や聴覚、触覚などの外部からの刺激を受け取る「感覚ニューロン」が（人工ニューラルネットワークにおける）**入力層**に相当し、筋肉に信号を送る「運動ニューロン」が**出力層**に相当します。




出典：https://www.researchgate.net/figure/Schematic-of-biological-neurons-connected-via-synapses_fig1_365372006

《プロンプト例》 生成 AI に質問して理解をもう一段階深めるとともに、知識の幅を広げましょう 🚀

- 👉 生理学・神経科学において、ニューロン同士はどのように情報を伝達していますか？そもそもニューロンとは何か、また、シナプス（Synapse）やアクソン（Axon）は、どのように情報伝達に関わっていますか？わかりやすく説明してください。
- 👉 人間の脳は約860億個のニューロンから構成されていると聞きました。その他の生物はどれぐらいのニューロンを持っていますか。

ニューロンによる情報伝達は、特徴的なメカニズムを持っています。まず、他のニューロンから放出された神経伝達物質を受け取ると、ニューロン内部の「電位」が**累積的に変化**します。この電位が一定の（ ）を超えると、接続先のニューロンへ向けて神経伝達物質を放出します。この現象を**発火**（Firing）と表現します（3Blue1Brown による人工ニューラルネットワークの解説でも、同じ用語が使われています）。さらに、発火時に各接続先へ伝わる信号は（ ）ではないという特徴もあります。

例として、次の図のようにニューロン ①A が、ニューロン ②B・③C・④D と接続しているような構成を考えます。このとき、①A が発火しても、そこから ②B・③C・④D に伝達される信号は均一ではなく、たとえば ②B には**励起性の信号**（＝電位を上昇させる）が、③C には**強い抑制性の信号**（＝電位を低下させる）が、そして ④D には**弱い抑制性の信号**が伝達されるといったように複雑な信号伝達の連鎖が生じます。



定着確認 生理学的なニューラルネットワークにおける「ニューロンによる信号伝達」に関する説明として最も適切なものはどれか。記号で答えよ。

- ① ニューロンは、隣接するニューロンから励起性の信号を受け取ると発火し、抑制性の信号を受け取ると発火が中止される。
- ② ニューロンは、隣接するニューロンから信号を受け取ると約 10ms 以内に発火する。
- ③ ニューロンは、隣接するニューロンから信号を受け取ると累積的に電位が変化し、その電位が閾値を超えると発火する。
- ④ ニューロンは、隣接する全てのニューロンから信号を受け取ったとき発火する。
- ⑤ ニューロンは、隣接するいずれかのニューロンから信号を受け取ったとき発火する。

定着確認 生理学的なニューラルネットワークの構造に関する説明として最も適切なものはどれか。記号で答えよ。


- ① ニューロンは基本的に 1 対 1 で双方向に接続されている。
- ② ニューロンは基本的に 1 対 1 で単方向に接続されている。
- ③ ニューロンは基本的に複数のニューロンと単方向で接続されている。
- ④ ニューロンは基本的に複数のニューロンと双方向で接続されている。

定着確認 生理学的なニューラルネットワークにおける信号伝達に関して正しい説明はどれか。最も適切なものを選び記号で答えよ。

- ① あるニューロンから他のニューロンに伝達される信号の強度は常に均一である。
- ② あるニューロンから他のニューロンに伝達される信号のタイプ(励起性/抑制性)は全て同じである。
- ③ ニューロンは受け取ったすべての信号を同じ強度で隣接するニューロンに伝える。
- ④ ニューロンは励起性の信号を受け取ると電位が上がり、抑制性の信号を受け取ると電位が下がる。
- ⑤ ニューロンは発火しているときに励起性の信号を伝え、そうでないときには抑制性の信号を伝える。

ニューラルネットワーク (機械学習・コンピュータサイエンス)

機械学習分野における**人工ニューラルネットワーク**(以下、単に「ニューラルネットワーク」と表記)とは、人間の脳機能を模倣した下図のようなネットワーク構造モデルを指します。図において ○ の部分がニューロン(神経細胞)に相当し、**各ニューロンは基本的に複数のニューロンと単方向で接続される構成**になっています。



ニューラルネットワークでは、**入力層**に x_1, x_2, x_3 を与えると、それらの値が**出力層**に向かって順次伝播し、最終的に出力値 y が得られます。適切に学習されたニューラルネットワーク、すなわち、**学習済みモデル**であれば、入力 x_1, x_2, x_3 に応じた適切な y を出力できるようになります。

例えば「本日の予想最高気温 x_1 」、「予想湿度 x_2 」、「先週の同じ曜日のアイスクリーム売上数 x_3 」を入力として与え、「本日のアイスクリーム予想売上数 y 」を出力させるといったことが可能になります。ニューラルネットワークの内部で、具体的にどのような計算によって x から y が決定されるのか、すなわち、 $y = f(x)$ が計算される仕組みについては、このあと詳しく学んでいきます。

ニューラルネットワークでは、このような連続値(実数値)の予測をする()タスクのほか、教師あり学習の()タスクも得意とします。**動画①②**のなかでは、手書き数字の画像を入力とする「分類」のタスクを例に、ニューラルネットワークの構造や学習の仕組みが解説されていました。

《プロンプト例》

👉 機械学習におけるニューラルネットワークの「入力層」と「出力層」とは何ですか。何を入力して、何が出来出力されるのですか？

ニューラルネットワークの種類

ニューラルネットワークは、一般に「入力層」「中間層（隠れ層）」「出力層」からなる層（Layer）構造を持ちます。中間層は 1 層以上存在し、特に 2 層以上の中間層を持つ構造は、一般に**多層パーセプトロン**（MLP : Multi-Layer Perceptron）や**深層ニューラルネットワーク**と呼ばれます。これらに加えて、

- ・畳み込みニューラルネットワーク（CNN : Convolutional Neural Network）
- ・再帰型ニューラルネットワーク（RNN : Recurrent Neural Network）

などのモデルを用いた機械学習手法は、一般に**ディープラーニング（深層学習）**と呼ばれています。

CNN は、主に**画像認識**（=CV : コンピュータビジョン）や**画像処理**のように画像を入力とするタスクにおいて強みを発揮します。CNN は画像から特徴を効果的・効率的に抽出するために設計されており、画像分類、物体検出、セグメンテーション（例えば、物体と背景の分離）などを得意とします。具体的な応用例としては、自動車の自動運転システムにおけるカメラ画像処理、医療画像診断における異常部位の検出、セキュリティシステムにおける顔認識技術などが挙げられます。

《プロンプト例》

👉 画像認識 (Computer Vision) と画像処理 (Image Processing) の違いについて教えてください。

RNN は、**時系列データ**や**シーケンスデータ**を扱うタスクで強みを発揮します。シーケンスデータとは**並び順に意味を持つデータ**のことで、文章や楽譜などがこれに該当します。RNN は過去の情報を記憶しながら順次処理を行なう特性を持っており、自然言語処理での文章生成、機械翻訳、音声認識、音楽生成（楽曲創出）、株価の時系列予測などを得意とします。さらに、LSTM（Long Short-Term Memory）や GRU（Gated Recurrent Unit）などの RNN の拡張モデルでは、長期的な依存関係を扱いやすくなり、例えば連続するイベントの予測や、より複雑な言語理解タスクにも適用されています。

《プロンプト例》

👉 RNN の拡張モデルである LSTM と GRU について概略を教えてください。ちなみに、RNN 自体もよく分かっていないので、その前提で順を追って解説してください。

なお、ChatGPT の基盤となっている Transformer モデル（これもディープニューラルネットワークの一種）は、RNN のように時系列データを順番に処理する仕組みとは異なり、**自己注意機構** (Self-Attention) というものを用いてテキストデータ全体の関係を同時に扱う特性を持っています。これにより、データ中の各要素が他の要素とどのように関連しているかを効率的に学習でき、長距離の依存関係を捉えることが可能になります。このような特徴により、自然言語処理 (NLP) の性能向上に大きく寄与しました。

動画①②では、最も単純な形のディープニューラルネットワークとして「MLP」を取り上げて解説しています。**動画①**の 2:07 では CNN と LSTM について、次のように紹介しています。

Convolutional neural network	→ Good for <u>image</u> recognition
Long short-term network	→ Good for <u>speech</u> recognition

定着確認 ニューラルネットワークの文脈において MLP とは何の略語か。最も適切なものを選び記号で答えよ。

- ① Modern Learning Protocol ② Multi-Layer Perceptron
- ③ Multiple Linear Programs ④ Memory Layer Protocol

定着確認 ChatGPT の基盤となる Transformer モデルが使用する特徴的なメカニズム（機構）はどれか。最も適切なものを選び記号で答えよ。

- ① Self-Attention ② Recurrent Units
- ③ Gate Layers ④ Perceptron Relays

定着確認 次のうち、ディープラーニング（深層学習）には属さないモデルはどれか。最も適切なものを選び記号で答えよ。

- ① MLP ② CNN ③ SVM ④ RNN ⑤ LSTM ⑥ Transformer

定着確認 畳み込みニューラルネットワークが得意とする領域（タスク）はどれか。最も適切なものを選び記号で答えよ。

- ① シーケンスデータの処理 ② 画像データの処理
- ③ 文章（テキストデータ）の処理 ④ 動画データの処理
- ⑤ 非構造化データの処理

定着確認 次のうち、「音声認識」に最も適するニューラルネットワークモデルはどれか。また「画像認識」に最も適するニューラルネットワークモデルはどれか。

- ① Multi-Layer Perceptron
- ② Convolutional Neural Network
- ③ Recurrent Neural Network
- ④ Generative Adversarial Network


MNIST (エムニスト)

MNIST (Modified National Institute of Standards and Technology database、エムニスト) とは、機械学習の分野で利用される「**手書き数字**」のデータセットです。増田知彰氏の「図解速習 DEEP LEARNING」によれば、MNIST は次のような由来となっています。


NIST (National Institute of Standards and Technology database) の 1 つに、米国の国勢調査局職員と高校生が手書きした数字を持つデータセットがありました。それを機械学習でより使いやすく改変 (Modified) したものが、"M" NIST です。

具体的には 0 から 9 までの「手書き数字のグレースケール画像」と「それに対応する正解ラベル」がペアになった 70,000 件のサンプル (学習用データ 60,000 件 + 検証用データ 10,000 件) から構成されています。各サンプルは 28 × 28 px 相当の **256** 階調のグレースケールで表現されており、JPEG や PNG のよ

うな画像ファイルではなく $28 \times 28 = 784$ の **8** ビット数値 (0~255) の配列として提供されています。
これを可視化した例を次に示します。



正解ラベル「3」




正解ラベル「5」

動画①②のなかでディープラーニング解説用に取り上げている手書き数字データも MNIST のデータとなっています。

演習 教材フォルダのなかの「mnist_train-00-raw.csv」「mnist_train-07-raw.csv」は、MNIST の学習用データのなかの 0 番目 (正解ラベル 5) と 7 番目 (正解ラベル 3) を CSV ファイルとして出力したものである。Excel などを利用して可視化せよ。


ヒント①: セル幅を調整

ヒント②: 条件付き書式のカラースケールを利用



MNIST に収録されているデータについて

MNIST には、学習用と検証用で合計 70,000 件の「手書き数字画像」と、その「正解ラベル」が収録されています。学習用 60,000 件は 250 名（半数が国勢調査局の職員、残りの半数が高校生）、また検証用 10,000 件には**学習用とは異なる 250 名を対象に作成**されています。以下に MNIST に収録されている手書き数字画像の一部を掲載します。人間でも判別が難しいデータも含まれることが確認できると思います。




参考 : [情報 3-第 04 回講義-補足資料@GoogleColab](#)

MLP の構造


既に解説したように MLP（多層パーセプトロン）は**入力層**、**2つ以上の中間層（隠れ層）**、**出力層**から構成されるニューラルネットワークであり、回帰や分類のための「教師あり学習」において汎用的に利用可能なモデルとなっています。

以下に示す MLP は、3 個のニューロンから構成される**入力層**、1 個のニューロンから構成される**出力層**を有しています。このようなモデルは**3つの特徴量** (x_1, x_2, x_3) から**1つの連続量** y_1 を予測するための（ ）タスクに用いることができます。




例えば、昨年のハーフマラソンのタイム x_1 、昨年からの体重変化 x_2 、直近 2 カ月の週平均トレーニング時間 x_3 の 3 つの情報を与え、来月開催されるハーフマラソンのタイム y_1 を予測するといった回帰タスクに利用できます。また、出力の扱いを工夫することで（ ）のタスクにも転用することが可能です。たとえば、果実表面の色 x_1 、柔らかさ x_2 、球形度 x_3 という 3 つの情報から「腐っている」「腐っていない」という二値分類をしたいときは、出力値 y_1 （通常 0.0 から 1.0 の範囲の連続量）に対して**閾値** (Threshold) を設定します。仮に閾値を 0.5 として、出力 y_1 が 0.5 未満なら「腐っていない」、0.5 以上なら「腐っている」のように運用することで、二値分類のタスクも扱うことができます。

一方、（ ）のタスクでは、以下に示すように分類したいカテゴリの個数（この例では 5 個）に対応したニューロンを出力層に用意します。




そして、出力層に配置されるニューロンからの出力値 $y_1 \sim y_5$ のうち、最も（ ）値をとるものに対応するカテゴリを分類結果として採用します。たとえば、出力層が $y_1 = 0.2$, $y_2 = 0.8$, $y_3 = 0.0$, $y_4 = 0.1$, $y_5 = 0.3$ となった場合、 y_2 に対応したカテゴリに分類・識別されたと考えます。このような MLP では、果実の色 x_1 、直径 x_2 、重量 x_3 という 3 つの特徴量から「スイカ」「メロン」「リンゴ」「カキ」「ミカン」の 5 種に分類するような**多値分類タスク**を扱うことができます。

動画①②では、画像として与えられる手書き数字を 0 から 9 までの 10 カテゴリに分類する**多クラス分類**を題材にしており、そこに使用している MLP の出力層は（ ）個のニューロンから構成されています。動画内の解説では**最も大きな値を出力しているニューロン**を「点灯している」と表現し、図的には白色や緑色で塗りつぶして表現しています。



また、分類に必要な**特徴量**として縦横 28 ピクセルの画像を**平坦化**した 784 個（ $=28 \times 28$ ）を扱うため、入力層は（ ）個のニューロンから構成されています。中間層（隠れ層、Hidden Layer）としては、16 個のニューロンを持った層を 2 つ設定しています。中間層の数や、それを構成するニューロンの数は（ハイパーパラメータと呼ばれ）任意に設定することができます。基本的には「層数」や「層を構成するニューロンの数」が多いほど、**学習次第では**複雑な分類や高精度な予測が可能になります。



出典：3Blue1BrownJapan @YouTube <https://www.youtube.com/watch?v=tc8RTtwvd5U>

ところで「0 から 9 に分類するタスクなので出力層に 1 個のニューロンを持つ回帰モデルを利用して、その出力 (0.0~1.0 の連続値) を 10 倍して 0.5 を引いて整数値に四捨五入する方法でもよいのでは？」と考えるかもしれません。しかし、この方法は適切ではありません。記号（シンボル）としての「1」と「7」は形状

が似ている一方で、数量としての「1」と「7」は大きく離れています。このように、数字を単純な連続値として扱おうと、データの本質的な構造を正しく反映できません。記号としての数字には、「6が3の2倍の大きさを持つ」といった比例関係や順序関係は意味を持たないため、このタスクに回帰モデルを用いるのは不適切です。

定着確認 16×16 ピクセルのグレースケール画像を用いて、トランプのスイート（スペード／クラブ／ハート／ダイヤ）の分類をしたい。MLP でモデルを構成するにあたり、「入力層」には何個のニューロンを配置すべきか答えよ。また「出力層」には何個のニューロンを配置すべきか答えよ。

定着確認 50×50 ピクセルの衛星画像（グレースケール画像）を用いて、その地域の植生密度を 0% から 100% の範囲で予測する場合、MLP でモデルを構成するにあたり、「入力層」には何個のニューロンを配置すべきか答えよ。また「出力層」には何個のニューロンを配置すべきか答えよ。

定着確認 40×40 ピクセルの気象レーダー画像（グレースケール画像）を用いて今後 1 時間の「降水量」と「落雷発生確率」を予測したい。MLP でモデルを構成するにあたり、「入力層」には何個のニューロンを配置すべきか答えよ。また「出力層」には何個のニューロンを配置すべきか答えよ。

補足：ChatGPT Images 2.0 のリリース

2026 年 4 月 22 日に、OpenAI から ChatGPT Images 2.0 の[リリースの発表](#)がありました（現地時間では 4 月 21 日の発表）。以下のように 2.0 からブランド表記が、GPT から ChatGPT に、Image から Images に変更されています。〔 〕内の表記は API モデルの名称です。

2025 年 03 月 4o Image Generation (GPT Image 1)	〔gpt-image-1〕
2025 年 12 月 GPT Image 1.5	〔gpt-image-1.5〕
2026 年 04 月 ChatGPT Images 2.0	〔gpt-image-2〕

ChatGPT Images 2.0 では、大幅に性能強化されています。詳細については[公式ウェブ](#)（作成例が多数掲載されています）や YouTube の[解説動画](#)などで確認してください。

教材フォルダに、本講義資料の p.108 の「ニューラルネットワークの種類」の解説を ChatGPT Images 2.0 にプロンプトとして与え、「図解」を作成させた例を配置しています。これまで課題であった文字の崩れ（特に日本語などの非ラテン文字の乱れ）も、大幅に改善されています。

以上のように、AI による画像生成技術は急速に高度化しており、「本物らしく見えるが実際には存在しない画像」を容易に作成できるようになってきています。いわゆる「ディープフェイク」の問題も含め、**画像そのものを根拠として事実を判断することは、今後、非常に危険になっていきます**。また、被害者や加害者となるトラブルも増えると予想されます。特に SNS のリポストでも、内容によっては名誉毀損が成立し、損害賠償請求が起こることもあるので十分に注意してください（[参考](#)）。

《プロンプト例》

👉 ディープフェイクの最前線（現在の技術動向、悪用事例など）について教えてください。

MLP における特徴量の前処理①

通常、MLP の入力層に与える特徴量は 0.0～1.0 の範囲の数値となります。そのため、気温のような情報を特徴量として使いたい場合、**正規化** (Normalization) * という**前処理** (Preprocessing) が必要になります。例えば、データセットに含まれる気温が -10°C ～ 45°C の範囲である場合、この範囲を 0.0 から 1.0 に変換する処理が必要になります。さらに「身長(cm)」と「年収(円)」のように尺度の異なる特徴量を(正規化せずに)そのまま使用してしまうと、学習(=ニューラルネットワークの重みの最適化)に悪影響を与えます。**動画①**においても、元データの輝度情報である「0 から 255」を、「0.0 から 1.0」に正規化して使用しています。

身長や年収といった**量的変数**ではなく、男女のような二値の**質的変数**の情報(Categorical Data : カテゴリカルデータ)は、男性を「0.0」、女性を「1.0」のように変換して入力層に与えます。一方、三値以上の**名義尺度の質的変数**、例えば「公大高専」「奈良高専」「明石高専」「神戸高専」「近大高専」の 5 つのカテゴリがあるような変数は、これらを独立した特徴量としてニューラルネットワークに入力するために、各高専に対応する要素だけが 1 で、残りが 0 の **One-hot ベクトル** (One-hot Vector) を使用します。具体的には、入力層に 5 つのニューロンを設け、以下のような特徴量 x_1, x_2, x_3, x_4, x_5 を設定します。

- ・ 公大高専 : $(x_1, x_2, x_3, x_4, x_5) = (1, 0, 0, 0, 0)$
- ・ 奈良高専 : $(x_1, x_2, x_3, x_4, x_5) = (0, 1, 0, 0, 0)$
- ・ 明石高専 : $(x_1, x_2, x_3, x_4, x_5) = (0, 0, 1, 0, 0)$
- ・ 神戸高専 : $(x_1, x_2, x_3, x_4, x_5) = (0, 0, 0, 1, 0)$
- ・ 近大高専 : $(x_1, x_2, x_3, x_4, x_5) = (0, 0, 0, 0, 1)$

このような変換は **One-hot エンコーディング** と呼ばれ、モデルに対してカテゴリ間での不必要な数値的関係を引き出すことなく、明確に特徴量を与えることができます。また、「小学生」「中学生」「高校生」「大学生」「大学院生」のような**順序尺度の質的変数**に関しては、それぞれ小学生を 0.0、中学生を 0.25、高校生を 0.5、大学生を 0.75、大学院生を 1.0 のように変換して扱うことが一般的です。この方法を使うと、入力層において、その情報を受け取るニューロンが 1 個で済むというメリットがあります。ここでは、「小学生」から「大学院生」までの 5 段階に対して等間隔に数値を割り当てましたが、修学年数に応じて間隔を調整するなどの工夫がモデルの精度向上に寄与する場合があります。一方で、小学生を 0.0、大学院生を 0.25、高校生を 0.5…のように順序を無視して扱っていると、モデルの精度が低下する可能性があります。

※ 質的変数、量的変数、名義尺度、順序尺度、間隔尺度、比例尺度については「情報 1」の第 11 回講義で学習済みです(忘れている場合は、復習しておいてください)。

定着確認 ニューラルネットワークに対する入力(特徴量)として「気温」を用いるとき、これに推奨される前処理はどれか。最も適切なものを記号で答えよ。

- ① 二値化 ② 正規化 ③ 正則化 ④ One-hot エンコーディング

* 正規化は、分野や文脈によって異なる意味を持ちます。正規化について検索する際には、どの分野に関する説明であるかを意識して、情報を読むことをお勧めします。

定着確認 次の特徴量のうち、ニューラルネットワークの入力として用いる際に One-hot エンコーディングが推奨されるものはどれか。最も適切なものを記号で答えよ。

- ① 血圧 ② 心拍数 ③ 血液型 ④ 輸血経験の有無 ⑤ 生物学的な性別

定着確認 ニューラルネットワークに用いる特徴量に対する前処理としての「正規化」について適切に説明しているものはどれか。最も適切なものを記号で答えよ。

- ① 特徴量の値をバイナリ（0 または 1）に変換する処理
② 特徴量の尺度を変更せず、データの平均を 0 にする処理
③ 特徴量から異常値（外れ値）を除去する処理
④ 特徴量の範囲を 0.0 から 1.0 にスケーリングする処理

定着確認 ニューラルネットワークに入力する特徴量の前処理として、常に One-hot エンコーディングが推奨されるものはどれか。最も適切なものを記号で答えよ。

- ① 名義尺度に属する情報
② 順序尺度に属する情報
③ 間隔尺度に属する情報
④ 比例尺度に属する情報

演習 教材フォルダのなかの「mnist_train-00-raw.csv」「mnist_train-07-raw.csv」を正規化し、「mnist_train-00-normal.csv」「mnist_train-07-normal.csv」として保存せよ。ただし、各値は小数第 5 位で四捨五入すること。

演習 教材フォルダのなかの「preprocessing-1.xlsx」は、「新入生が高専ではどの部活に入るか？」という予測タスクのための（仮定の）学習用データセットである。このデータセットには、入力（特徴量）として「性別」「中学校での部活動」「通学時間（分）」「得意科目」「不得意科目」が設定されており、正解ラベルとして「高専での部活動」が用意されている。データには欠損値も含まれている。MLP を使った機械学習の入力に使用するために、適切な前処理（正規化や One-hot エンコーディング、その他）を適用せよ。

※ この処理は、手作業で行わず、関数またはマクロ（VBA）などを利用すること。

※ 欠損値についてどのように扱うべきかについてはウェブや生成 AI を利用して解決すること。

MLP における特徴量の前処理②

MLP を用いて、**特徴量に「画像」を用いた機械学習**を行なう場合の前処理について考えていきます。MNIST の手書き数字画像のように既に画像サイズが統一された「グレースケール画像」や「白黒画像」であれば、それらを平坦化、つまり 2 次元データを 1 次元データに変換し、正規化したものを特徴量として使用します。

また、カラー画像は各ピクセルが RGB の色情報を持つため「縦」「横」「色」の 3 次元のデータとなりますが、これも同様に平坦化、正規化して特徴量とします。例えば、 28×28 ピクセルのカラー画像を特

微量とする場合、入力層には（ ） = 2,352 個のニューロンを配置します。また、色表現を RGB から（ ） : 色相・彩度・明度）に変換してから平坦化する場合もあります。RGB でも HSV でも、グレースケール画像と比較して特徴量は（ ） 倍になるため、学習フェーズの計算負荷は増大し、それにともない学習にかかる時間も長くなります。そのため、色情報が大きな意味を持たないケース（例えば文字認識など）では前処理としてグレースケール化することもあります。

また、機械学習に使用する画像をインターネットから収集する場合、画像サイズは基本的にバラバラとなってしまいます。このような場合、**画像を適切な大きさにリサイズする必要があります**。リサイズする際は、オリジナル画像の（ ） : 縦横比）を維持するか否か、維持するとすれば余白が生じるが、それを何色で埋めるのかといったことも設定する必要があります。また、何ピクセル×何ピクセルに揃えてリサイズするかについても検討する必要があります。このような前処理は、学習フェーズにおける計算負荷や、推論フェーズにおけるモデルの性能に対して少なからぬ影響を及ぼします。

以上のように、機械学習においては多数のデータを準備するだけでなく、それらに対する適切な前処理が必要となります。適切な前処理を施さない場合、たとえ最新のモデルやアルゴリズムを用いた機械学習をしても、高い精度のモデルを得ることはできないことを覚えておいてください。

定着確認 MLP による深層学習に「画像」を特徴量として用いる場合、一般に必要な前処理はどれか。最も適切なものを記号で答えよ。

- ① 色の反転 ② 平坦化と正規化 ③ カラーフィルタの適用 ④ 高解像度化

定着確認 MLP による深層学習に 32×32 ピクセルのカラー画像を平坦化して用いる場合、入力層に必要なニューロンの数はいくつか。

定着確認 深層学習に用いる画像の前処理として RGB を HSV に変換するメリットは何か。最も適切なものを記号で答えよ。

- ① 画像を構成するピクセル数を減らすことができる
② 透過情報を扱うことができる
③ 画像ファイルのサイズを小さくすることができる
④ 色情報をより人間の視覚に即した形で表現できる
⑤ 画像のコントラストを高めることができる

定着確認 画像を特徴量に用いる機械学習において、高解像度の画像を使用するメリットまたはデメリットに関する説明として不適切なものはどれか。記号で 1 つ答えよ。

- ① 高解像度の画像は情報量が多く、物体の特徴をより精密に抽出可能なため、認識精度が向上する可能性がある。
② 高解像度の画像はファイルサイズが大きくなるため、学習に必要な計算資源や時間が増加する。
③ 高解像度の画像を使用することで、学習に必要な画像の枚数を減らすことができる。
④ 高解像度の画像は、複雑なテクスチャや細かいディテールを含むことが多いため、場合によっては過学習を引き起こす可能性がある。

ニューロン出力値の計算①

ここでは、ニューラルネットワークの入力層に特徴量 $\mathbf{x} = (x_0, x_1, \dots, x_n)$ が与えられたとき、出力層の出力値 y が**どのように導かれるか**について順を追って見ていきます。以降の説明では、添え字は原則としてゼロオリジンの添え字を採用します（先頭を 1 ではなく 0 からカウントする表現です）。




Fig. 1 ニューラルネットワークの信号伝搬

まず、**入力層** (Layer 0) では、通常、入力データとして与えられる特徴量 $x_0 \sim x_2$ が、そのまま各ニューロンの出力値 $a_0^{(0)} \sim a_2^{(0)}$ となります。ここでの $a_0^{(0)}$ の上付き文字の 0 は、「べき乗」の意味ではなく、「第 0 層の…」という意味になります（そのために、あえて括弧をつけています）。このニューロンの出力値のことを**動画①**では「**アクティベーション** (Activation、活性化値)」と呼称しています。

入力層 (Layer 0) の各ニューロンの出力値には、**重み係数 w** (接続強度) が乗算されて Layer 1 のニューロンに伝達されます。ここでは、前層の p 番目のニューロンから、次層の q 番目のニューロンに向かう接続の重みを () のように表します (添え字の順序に注意)。重み w は、0 や () をとることもあります。この重み w は、学習フェーズにおいて、**学習用データセットとアルゴリズムを用いて最適化される対象**となります。すなわち、重み w の最適化こそが「学習」の核心であるといえます。

例：Layer 0 の 0 個目のニューロンの出力 $a_0^{(0)}$ は、重み $w_{1,0}$ を乗じた値、すなわち、 $w_{1,0} \cdot a_0^{(0)}$ として Layer 1 の 1 個目のニューロンに入力されます。

定着確認 Fig.1 のモデルにおいて、Layer 0 の 2 個目のニューロンから、Layer 1 の 1 個目のニューロンに入力される値を答えよ *。

ニューロン出力値の計算② 活性化関数

Layer 1 の各ニューロンでは、Fig. 1 の図内に示したような数式により、各ニューロンの出力値 $a_0^{(1)}$ および $a_1^{(1)}$ が計算されます。

$$a_0^{(1)} = \sigma(w_{0,0} a_0^{(0)} + w_{0,1} a_1^{(0)} + w_{0,2} a_2^{(0)} + b_0)$$


* 答え： $w_{1,2} \cdot a_2^{(0)}$

基本的には前層の出力値に重みを乗じたものの総和に**バイアス** b を加え、その結果に**活性化関数** σ を適用したものが、次層に向けた出力値となります。

活性化関数 (Activation Function) は、ニューラルネットワークモデルに「非線形性」を与えるもので、**動画①**のなかでは（ ）関数というものを採用し、それを記号 σ で表していました。非線形な性質が付与されることで、入力と出力の複雑な対応関係を表現できるようになります。シグモイド関数 (Sigmoid Function) は、次のように定義される関数となっています。

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

横軸を x 、縦軸を $y = \sigma(x)$ としてシグモイド関数を描くと次のようになります。




さらに、シグモイド関数を適用することでニューロンの出力値を 0.0 から 1.0 の範囲に収めることができます。

《プロンプト例》

- 👉 ニューラルネットワークにおいて、活性化関数としてシグモイド関数を使用することで、出力が0.0から1.0の範囲に収まることのメリットについて初学者にも分かるように解説してください。また、デメリットについても解説してください。
- 👉 ニューラルネットワークにおいて、「シグモイド関数などによって、非線形性が付与されると入力と出力の複雑な対応関係を表現できるようになる」と習ったのですが、イメージが付きません。興味があるので、初学者でもイメージがつかめるように解説してください。

定着確認 シグモイド関数 $\sigma(x)$ において、 $x = -\infty$ 、 $x = 0$ 、 $x = \infty$ の各場合における $\sigma(x)$ の値をそれぞれ答えよ。

なお、近年のニューラルネットワークモデルでは、**計算が単純**で「**勾配消失**」の影響が少ないことから、シグモイド関数よりも **ReLU 関数** (Rectified Linear Unit 関数、レール関数) が活性化関数として頻繁に利用されています (**動画① 16:40** を参照)。ReLU 関数は、 $f(x) = \max(0, x)$ のように定義される関数で、横軸に x 、縦軸を $y = f(x)$ として描くと次のようになります。



シグモイド関数、ReLU 関数のいずれも「隣接するニューロンからの入力が増えるまでは、出力がほとんど 0 に保たれる（つまり発火しない）」という点で、生理学的なニューロンの挙動を模倣していることが分かります。

ニューロン出力値の計算③ バイアス

シグモイド関数や ReLU 関数では、入力値が 0 を境に出力の振る舞いに変化するため、0 を実質的な閾値とみなすことができます。この基準を前後にシフトして**発火のしやすさを調整する役割**を担うのが「**バイアス (Bias)**」となります。バイアスは数式中では b と表され、この値が大きいほど入力の総和が小さくてもニューロンは発火しやすくなり、逆に負の値をとる場合には、より大きな入力が必要であれば発火しにくくなります。このバイアス b も、重み係数 w と同様に（ ）フェーズで最適化する値となります。具体的には（ ）：Backpropagation）というアルゴリズムを用いて、繰り返し計算（主に偏微分）を行いながら「重み」と「バイアス」を最適化します。誤差逆伝播法は、3 年後期の「解析 2」において、数学的な観点からの解説が予定されています。

以上を整理すると Layer 1 の各ニューロンの出力値（アクティベーション）は、次のように記述することができます。ここからは、汎用性を持たせるために、活性化関数を表す記号として σ ではなく f を使用して表記していきます。

$$a_0^{(1)} = f(w_{0,0} a_0^{(0)} + w_{0,1} a_1^{(0)} + w_{0,2} a_2^{(0)} + b_0)$$

$$a_1^{(1)} = f(w_{1,0} a_0^{(0)} + w_{1,1} a_1^{(0)} + w_{1,2} a_2^{(0)} + b_1)$$

これを行列で表現すると次のようになります（動画① [13:05](#) を参照してください）。

$$\begin{bmatrix} a_0^{(1)} \\ a_1^{(1)} \end{bmatrix} = f \left(\begin{bmatrix} w_{0,0} & w_{0,1} & w_{0,2} \\ w_{1,0} & w_{1,1} & w_{1,2} \end{bmatrix} \begin{bmatrix} a_0^{(0)} \\ a_1^{(0)} \\ a_2^{(0)} \end{bmatrix} + \begin{bmatrix} b_0 \\ b_1 \end{bmatrix} \right)$$


さらに、行列表記をベクトル・行列の太字記法で表すと、次のように書くことができます。

$$\mathbf{a}^{(1)} = f(\mathbf{W} \cdot \mathbf{a}^{(0)} + \mathbf{b})$$

このうち $\mathbf{W}$ と $\mathbf{b}$ が、学習によって最適化（調整）されるパラメータとなります。先に示した Layer 0 と 1 から構成されるニューラルネットワークでは（ ） = 8 個がパラメータの総数となります。ここで、重みが Layer 0 と Layer 1 の結合に対応することを明示するために $\mathbf{W}$ を $\mathbf{W}^{(0,1)}$ とし、バイアスが Layer 1 に属することを示すために $\mathbf{b}$ を $\mathbf{b}^{(1)}$ のように表すと、次のように表せます。

$$\mathbf{a}^{(1)} = f(\mathbf{W}^{(0,1)} \cdot \mathbf{a}^{(0)} + \mathbf{b}^{(1)})$$

モデルを拡張し、以下のように Layer 1 の後に Layer 2、Layer 3 がつくモデルを考えます。



Layer 2 のニューロンの出力値 $\mathbf{a}^{(2)}$ は、次のように表されます。

$$\mathbf{a}^{(2)} = f(\mathbf{W}^{(1,2)} \cdot \mathbf{a}^{(1)} + \mathbf{b}^{(2)}) = f(\mathbf{W}^{(1,2)} \cdot (f(\mathbf{W}^{(0,1)} \cdot \mathbf{a}^{(0)} + \mathbf{b}^{(1)})) + \mathbf{b}^{(2)})$$

同様に、Layer 3 のニューロンの出力値 $\mathbf{a}^{(3)}$ は、次のように表されます。

$$\mathbf{a}^{(3)} = f(\mathbf{W}^{(2,3)} \cdot \mathbf{a}^{(2)} + \mathbf{b}^{(3)}) = f(\mathbf{W}^{(2,3)} \cdot f(\mathbf{W}^{(1,2)} \cdot (f(\mathbf{W}^{(0,1)} \cdot \mathbf{a}^{(0)} + \mathbf{b}^{(1)})) + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

このニューラルネットワーク全体で最適化の対象となるパラメータは、重みとバイアスを合わせて () = 17 個となります。

定着確認 MLP を使用した機械学習の「学習フェーズ」において、誤差逆伝播法などを通じて最適化するパラメータは次のうちどれか。該当するものをすべて答えよ。


- ① 特徴量（入力値）
- ② 中間層の層数と、各中間層を構成するニューロンの数
- ③ 各ニューロンのバイアス
- ④ 各ニューロンの出力値
- ⑤ 各ニューロン間の重み係数
- ⑥ 予測値（出力値）

定着確認 784 個のニューロンからなる入力層、16 個のニューロンからなる中間層 1、16 個のニューロンからなる中間層 2、10 個のニューロンからなる出力層を持ち、各層が全結合されている MLP において、学習フェーズで最適化されるパラメータの総数を求めよ。

定着確認 ニューラルネットワークにおいて、バイアスが果たす役割として最も適切なものを 1 つ選び、記号で答えよ。

- | | |
|---------------------|-----------------|
| ① 入力値のスケールを正規化する | ② 活性化関数の種類を決定する |
| ③ ニューロンの発火しやすさを調整する | ④ 出力層の次元数を決定する |

定着確認 次の図に示すニューラルネットワークにおいて、Layer 1 の 0 番目のニューロンの出力値 $a_0^{(1)}$ を数式で示せ。Layer 1 の 0 番目のニューロンのバイアスを b_0 、活性化関数を f として答えること。



定着確認 ニューラルネットワークの活性化関数として使用される ReLU 関数を表したものはどれか。また、シグモイド関数を表したものはどれか。記号で答えよ。

- ① $f(x) = \max(0, x)$
- ② $f(x) = \min(0, x)$
- ③ $f(x) = (1 + e^{-x})^{-1}$
- ④ $f(x) = (1 - e^{-x})^{-1}$

定着確認 ニューラルネットワークにおける「重み係数」と「バイアス」が取りうる数値の範囲について、正しい説明をしているものはどれか。最も適切なものを記号で答えよ。

- ① 重み係数は 0 以上の実数のみをとる、バイアスも 0 以上の実数のみをとる。
- ② 重み係数もバイアスも任意の実数をとる。
- ③ 重み係数は 0 以上の実数のみをとるが、バイアスは任意の実数をとる。
- ④ 重み係数は任意の実数をとるが、バイアスは 0 以上の実数のみをとる。

定着確認 ニューラルネットワークの学習に使用される「誤差逆伝播法」に最も関連深い数学の分野はどれか。最も適切なものを記号で答えよ。

- ① 確率 ② 統計 ③ 偏微分 ④ 重積分 ⑤ 複素数 ⑥ 幾何学

定着確認 次の式は、MLP（多層パーセプトロン）において、前層の出力から第 k 層の出力を計算する順伝播の関係式である。このうち、学習フェーズにおいて最適化されるものをすべて選べ。


$$\mathbf{a}^{(k)} = f(\mathbf{W}^{(k-1,k)} \cdot \mathbf{a}^{(k-1)} + \mathbf{b}^{(k)})$$

- ① $\mathbf{a}^{(k)}$ ② $\mathbf{W}^{(k-1,k)}$ ③ $\mathbf{a}^{(k-1)}$ ④ $\mathbf{b}^{(k)}$ ⑤ f

活性化関数（アクティベーション関数）の役割

動画①の [10:00](#) 付近では、シグモイド関数の適用に関して「このネットワークでは、アクティベーション（＝ニューロンの出力値）は 0 から 1 の値になってほしいので」のように解説しています。しかし、「シグモイド関数」や「ReLU 関数」などの**活性化関数（アクティベーション関数）をニューロンの出力値に用いる本質的な意味**は（出力値を 0.0 から 1.0 にスケールすることではなく）ニューラルネットワークに**非線形性を持たせること**にあります。この非線形性によって、モデルはより複雑な予測や分類を可能としています。

例えば、次のような中間層を有する MLP において、各ニューロンの出力値の決定に**活性化関数 f を適用しない場合**について考えてみます。



まず、Layer 0 の出力 $\mathbf{a}^{(0)}$ は、次のように入力 $\mathbf{x}$ と等しくなります。

$$\begin{bmatrix} a_0^{(0)} \\ a_1^{(0)} \end{bmatrix} = \begin{bmatrix} x_0 \\ x_1 \end{bmatrix}, \quad \mathbf{a}^{(0)} = \mathbf{x}$$

つづいて Layer 1 の出力 $\mathbf{a}^{(1)}$ は、次のようになります。

$$\begin{bmatrix} a_0^{(1)} \\ a_1^{(1)} \end{bmatrix} = \begin{bmatrix} w_{0,0}^{(0,1)} & w_{0,1}^{(0,1)} \\ w_{1,0}^{(0,1)} & w_{1,1}^{(0,1)} \end{bmatrix} \begin{bmatrix} a_0^{(0)} \\ a_1^{(0)} \end{bmatrix} + \begin{bmatrix} b_0^{(1)} \\ b_1^{(1)} \end{bmatrix} = \begin{bmatrix} w_{0,0}^{(0,1)} & w_{0,1}^{(0,1)} \\ w_{1,0}^{(0,1)} & w_{1,1}^{(0,1)} \end{bmatrix} \begin{bmatrix} x_0 \\ x_1 \end{bmatrix} + \begin{bmatrix} b_0^{(1)} \\ b_1^{(1)} \end{bmatrix}$$

$$\mathbf{a}^{(1)} = \mathbf{W}^{(0,1)}\mathbf{x} + \mathbf{b}^{(1)} \quad \dots (1)$$

つづいて、Layer 2 の出力 $\mathbf{a}^{(2)}$ を考えます。


$$\begin{bmatrix} a_0^{(2)} \\ a_1^{(2)} \end{bmatrix} = \begin{bmatrix} w_{0,0}^{(1,2)} & w_{0,1}^{(1,2)} \\ w_{1,0}^{(1,2)} & w_{1,1}^{(1,2)} \end{bmatrix} \begin{bmatrix} a_0^{(1)} \\ a_1^{(1)} \end{bmatrix} + \begin{bmatrix} b_0^{(2)} \\ b_1^{(2)} \end{bmatrix}$$

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1,2)}\mathbf{a}^{(1)} + \mathbf{b}^{(2)} \quad \dots (2)$$

上記の式 (2) に 式 (1) を代入します。

$$\begin{aligned} \mathbf{a}^{(2)} &= \mathbf{W}^{(1,2)}(\mathbf{W}^{(0,1)}\mathbf{x} + \mathbf{b}^{(1)}) + \mathbf{b}^{(2)} \\ &= \mathbf{W}^{(1,2)}\mathbf{W}^{(0,1)}\mathbf{x} + \mathbf{W}^{(1,2)}\mathbf{b}^{(1)} + \mathbf{b}^{(2)} \\ &= (\mathbf{W}^{(1,2)}\mathbf{W}^{(0,1)})\mathbf{x} + (\mathbf{W}^{(1,2)}\mathbf{b}^{(1)} + \mathbf{b}^{(2)}) \quad \dots (3) \end{aligned}$$

ここで、式 (3) の第 1 項の係数 $\mathbf{W}^{(1,2)}\mathbf{W}^{(0,1)}$ を $\mathbf{W}'$ とします。また、第 2 項を $\mathbf{b}'$ とします。そうすると式 (3) は $\mathbf{y} = \mathbf{W}'\mathbf{x} + \mathbf{b}'$ のように書いてしまいます。これは、次に示すようなニューラルネットワークと等価であることを意味します。



つまり、ニューロンの出力計算に**非線形の活性化関数 f** を用いなければ、**どれだけ多くの中間層を追加しても、そのネットワークは「単層のニューラルネットワークでも表現できるもの」と同等の表現力しか持ちません**。当然ながら、そのようなモデルでは複雑な予測や分類を行うことはできません。


定着確認 ニューラルネットワークにおける活性化関数の主たる役割はなにか。最も適切なものを記号で答えよ。

- ① 誤差逆伝播法を適用する際、誤差勾配を効率的に伝播させる。
- ② 各層の出力を正規分布に近似させる。
- ③ ニューラルネットワークに非線形性を導入する。
- ④ ニューロンの出力を特定の範囲内に収める。

定着確認 非線形の活性化関数を使用しない MLP は、どのようなモデルと等価といえるか。最も適切なものを記号で答えよ。

- ① 単層ニューラルネットワーク
- ② 線形重回帰モデル
- ③ 多変量線形回帰モデル
- ④ 単一の線形分類器
- ⑤ サポートベクターマシン

定着確認 活性化関数 f を使用しない場合、以下に示すニューラルネットワーク A は、ニューラルネットワーク A' に等価変換することができる。ニューラルネットワーク A のパラメータ $\mathbf{W}^{(0,1)}$ 、 $\mathbf{W}^{(1,2)}$ 、 $\mathbf{b}^{(1)}$ 、 $\mathbf{b}^{(2)}$ が以下のように与えられるとき、それと等価なニューラルネットワーク A' のパラメータ $\mathbf{W}'$ および $\mathbf{b}'$ の値を求めよ。



$$\mathbf{W}^{(0,1)} = \begin{bmatrix} 0.4 & 0 \\ 0.5 & 1 \end{bmatrix}, \quad \mathbf{W}^{(1,2)} = \begin{bmatrix} -0.2 & 0.8 \\ -0.5 & 0.5 \end{bmatrix}, \quad \mathbf{b}^{(1)} = \begin{bmatrix} 0.4 \\ 0.2 \end{bmatrix}, \quad \mathbf{b}^{(2)} = \begin{bmatrix} 0.3 \\ 0.2 \end{bmatrix}$$

大学入学共通テスト「情報」に挑戦 ④

大学入学共通テスト（＝皆さんと同学年の高校 3 年生が受験することになる試験）の「情報」からの抜粋です。今回は、読解力が問われる内容となっています（問題文は長いですが内容は簡単です）。

第 1 問 問 4 次の文章を読み、後の問い（a・b）に答えよ。

マウスカーソルをメニューやアイコンなどの対象物に移動する操作をモデル化し、Web サイトやアプリケーションのユーザインタフェースをデザインする際に利用されている法則がある。この法則では、次のことが知られている。

- ・対象物が大きいくほど、対象物に移動するときの時間が短くなる。
- ・対象物への距離が短いほど、対象物に移動するときの時間が短くなる。

a 次の文章中の空欄【ア】に入れるのに最も適当なものを、図 1 の①～③のうちから一つ選べ。

この法則では、PC などマウスを操作する場合、マウスカーソルはディスプレイの端で止まるため、ディスプレイの端にある対象物は実質的に大きさが無限大になると考える。この法則に基づくと、図 1 の①～③で示した対象物のうち、現在ディスプレイ上の黒矢印で示されているマウスカーソルの位置から、最も短い時間で指し示すことができるのは【ア】である。




図 1 ディスプレイ上の対象物

b 次の文章中の空欄【イ】【ウ】に入れるのに最も適当なものを、後の解答群のうちから一つずつ選べ。

操作時間を短くするためにこの法則を適用した事例として、利用頻度に基づいてメニュー項目を配置する方法がある。

ここでは、マウスを右クリックした際に、マウスカーソルに対して図 2 に示すような位置で表示されるメニュー項目の配置について考える。マウスカーソルで選択できる各メニュー項目の大きさは同じであるとし、この法則のみに沿って設計されたとなると、「項目 5」は、他の項目と比べ利用頻度が【イ】項目なので、意図的に【ウ】に配置されていると考えられる。




図 2 右クリックした際のメニュー項目

【イ】の解答群

- ① 低い ② 同程度の ③ 高い

【ウ】の解答群

- ① メニューの中で一番目立つ場所
② マウスカーソルの位置から遠い場所
③ マウスで素早く選択できる場所

2026 年度（追試） 第 1 問 問 1 次の問い (a・b) に答えよ。

a 任意の時刻をビット列で表すことを考える。24 時間制で、時と分をそれぞれ h ビットと m ビットのビット列で別々に表す。 h と m をそれぞれ最小のビット数にする場合、 $h+m$ はいくつになるか。最も適当なものを、次の①～④のうちから一つ選べ。

- ① 9 ② 10 ③ 11 ④ 12 ⑤ 13

b 情報通信ネットワークに関する説明として、最も適当なものを、次の①～③のうちから一つ選べ。

- ① 同一ネットワークにある複数のコンピュータ間で通信するためには、それらのコンピュータに同一の IP アドレスを割り当てる必要がある。
② ルータ、ハブ、DNS サーバがそろっていなければ、LAN を構築することはできない。
③ 通信プロトコルのひとつである TCP には、通信経路においてデータが失われた場合、失われたデータを送り直す機能が備わっている。
④ パケット交換方式による通信では、データを統合してパケットという形式にすることで、回線を占有することを可能にしている。

2026 年度（追試） 第 1 問 問 2 次の文章を読み、空欄【ウ】【エ】に入れるのに最も適当なものを、後の解答群のうちから一つずつ選べ。

ゲノムとは生物が持つすべての遺伝情報のことであり、 $A \cdot T \cdot G \cdot C$ の 4 種類の文字の列で表現される。ヒトゲノム（人間のゲノム）はおよそ 30 億もの長さの文字列となり、その文字列中には同じパターンが何度も出現する。何度も出現するパターンに記号を割り当てる処理を繰り返し行うことで、文字列を簡潔に表現できる場合がある。

例として、次の (1) のような文字列を考える。

GTTGTTATTGTTGTT … (1)

ここで、GTT というパターンに記号 α 、ATT というパターンに記号 β を割り当てれば、(1) は次の (2) のように表現できる。

$\alpha\alpha\beta\alpha\alpha$, $\alpha=\text{GTT}$, $\beta=\text{ATT}$ … (2)

さらに $\alpha\alpha$ というパターンに記号 γ を割り当てれば、次の (3) のように表現できる。

$\gamma\beta\gamma$, $\alpha=\text{GTT}$, $\beta=\text{ATT}$, $\gamma=\alpha\alpha$ … (3)

同様にして、次の (4) の文字列に対して、GTT に α 、ATT に β を割り当てる。

GTTGTTGTTATTGTTATTGTTATTGTT … (4)

さらに $\beta\alpha$ というパターンに記号 γ を割り当てれば、(4) は次の (5) のように表現できる。

$$\text{【ウ】}, \quad \alpha = \text{GTT}, \quad \beta = \text{ATT}, \quad \gamma = \beta\alpha \quad \dots (5)$$

また、**【エ】** という別のパターンに記号 γ を割り当てれば、(4) は次の (6) のように表現できる。

$$\alpha\alpha\gamma\beta\gamma, \quad \alpha = \text{GTT}, \quad \beta = \text{ATT}, \quad \gamma = \text{【エ】} \quad \dots (6)$$

【ウ】 の解答群

- | | | |
|---|--|---|
| ① $\alpha\alpha\alpha\gamma\gamma\alpha\beta$ | ① $\alpha\alpha\alpha\gamma\gamma\gamma$ | ② $\alpha\alpha\beta\gamma\gamma\gamma$ |
| ③ $\alpha\alpha\gamma\gamma\gamma\alpha$ | ④ $\alpha\alpha\gamma\gamma\gamma\beta$ | ⑤ $\alpha\gamma\gamma\gamma\gamma$ |

【エ】 の解答群

- | | | | |
|-----------------------|-----------------------|-----------------------|----------------------|
| ① $\alpha\alpha$ | ① $\alpha\beta$ | ② $\beta\alpha$ | ③ $\beta\beta$ |
| ④ $\alpha\alpha\beta$ | ⑤ $\alpha\beta\alpha$ | ⑥ $\beta\alpha\alpha$ | ⑦ $\alpha\beta\beta$ |
| ⑧ $\beta\alpha\beta$ | ⑨ $\beta\beta\alpha$ | | |

授業時間外の学習指示

本科目は学修単位であり、**授業時間以外に 4 時間/週の自学自習が要求される科目**です。講義資料のボリュームも試験の難易度も、それを前提に設計・調整しています。また、授業時間外学習を疎かにすると、本科目のほか、PC を利用する授業や実験実習についていくことが難しくなります。最大限、取り組むように心がけてください。

- (1) この講義ノートを再読・熟読し「不明な用語」「理解が十分ではない用語」についてインターネットや ChatGPT などの生成 AI を利用して解決してください。また、興味関心を持ったトピックについて、ウェブ、生成 AI、YouTube 動画などを利用して知識を広げ、理解を深めてください。
- (2) 講義ノート内の**演習**に再度取り組んでください。演習は、授業時間中に 1 回取り組むだけでは定着しないので注意してください。
- (3) **定着確認**に取り組んでください。なお、**定着確認の解答例は公開しません**。技術者には、自分自身で解の妥当性を検証し、責任を負うことが求められます。その訓練と考えてください（ウェブや生成 AI を活用すれば、短時間で解の妥当性が検証できるので、その手間を惜しまないでください）。
- (4) 課題②が未完了の場合、引き続き取り組んでください。**提出期限は第 05 回講義の前日 13 時です**。
- (5) 今回授業の発展的内容として、次の動画を視聴してください。
 - [深層学習（ディープラーニング）Chapter2 深層学習の仕組み、勾配降下法](#)（再）
 - [深層学習（ディープラーニング）Chapter3 誤差逆伝播法（バックプロパゲーション）](#)
- (6) 次回授業も引き続き「**ディープラーニング基礎演習**」としてニューラルネットワークやディープラーニング(深層学習)に関する内容を取り上げます。次回は [Teachable Machine](#) と [TensorFlow Playground](#) というウェブサービスを使用します。[Teachable Machine](#) は 1 年生の総合工学システム実験実習（I コースのテーマ）で全員が一度は利用しているものです。次回授業に向けた準備・予習として以下のチュートリアル動画を視聴し、これらのサイトにアクセスして実際に操作を試みてください。予習を

通じて予備知識を身につけ、理解できない点や疑問点を明確にしておくことで、授業の効果を最大限に高めることができます。


→ 予習①-動画 : [Teachable Machine のチュートリアル](#) (ゆっくり解説) 8 分 2 秒

→ 予習① : [Teachable Machine](#)

→ 予習②-動画 : [TensorFlow Playground のチュートリアル](#) (日本語字幕) 5 分 3 秒

→ 予習② : [TensorFlow Playground \(日本語訳 Version\)](#)

→ 予習② : [TensorFlow Playground](#)



次回授業：小テスト実施

次回の授業で**小テスト**を実施します。

スキルチェックシート

情報 1・2 と同様に Microsoft Forms の設問に回答し、自分の ICT・AI 利活用スキルを客観的に把握してください。少なくとも次回授業の前日 12 時までには、初回の回答を終えてください（その後、スキルアップしたら随時更新してください）。

回答のスコアの高低は成績評価に反映しませんが、「回答遅れ」や「未回答」があれば成績評価のなかの「課題（35%）」の項目から減点します。



<https://forms.office.com/r/Xqa6U9vT77>