

以下、前回の講義ノートの **授業時間外学習** で指示したように [Teachable Machine](#) と [TensorFlow Playground](#) のチュートリアル動画を事前に視聴し、さらに各サイトにアクセスして実際に操作を試していることを前提とした内容となります。

Teachable Machine：画像ファイルを使用した学習①

[Teachable Machine のチュートリアルとして紹介した動画](#)のなかでは、（ ） からリアルタイムに取得した画像を基に、機械学習による画像分類（二値分類／多クラス分類）を行なう方法について紹介されていました。ここではカメラから取得する画像ではなく、**予め用意した「画像ファイル」を使って Teachable Machine に学習と分類をさせる方法**についてチュートリアル形式で解説していきます。学習用のデータセット（画像）には、前回講義で紹介した MNIST を引き続き使用し、手書きの数字画像を「0」から「9」までの **10 クラス**（＝10 カテゴリ）に分類するタスクを扱っていきます。

[Teachable Machine](#) の「**画像プロジェクト**」では、ウェブカメラからの映像を利用するほかに PNG 形式、BMP 形式、JPEG 形式（*.jpeg *.jpg *.jfif *.pjpeg *.ppj）の画像ファイルを使って学習用データセットを与えることができます。また、各形式の複数ファイルを Zip 圧縮したファイルでデータセットを与えることもできます。特に大量のデータを与える場合は、**Zip 圧縮で 1 ファイルにまとめてデータセットを与えることが推奨**されます。

教材フォルダのなかの MNIST-training-data には、「0」から「9」までの手書き数字の PNG 画像について、クラスごとに 50 枚（000.png～049.png）をまとめた Zip ファイルを格納しています。これらのファイルは以下の手順で Teachable Machine に与えることができます。

- (1) ウェブブラウザから [Teachable Machine](#) にアクセスし、トップページから順に「**使ってみる**」、「**画像プロジェクト**」、「**標準の画像モデル**」の順にボタンを押下してください。
- (2) デフォルトで作成されている「**Class 1**」の「**画像サンプルを追加する**」の項目から下図のように「**アップロード**」を選択してください。




なお、Teachable Machine の画面上では「アップロード」と表示されていますが、**ここで指定した画像ファイルがクラウド（＝インターネット空間）にアップロードされるわけではありません**。ここでの「アップロード」とは、指定ファイルを、ローカル PC のウェブブラウザ上で動作する Teachable Machine（＝JavaScript プログラム）のメモリ空間に転送することを意味しています。

- (3) MNIST-training-data フォルダの「img-1.zip」を下図の**赤枠で囲んだ領域にドラッグ&ドロップ**してください。なお、赤枠をクリックして「ファイル選択ダイアログ」からファイル指定することも可能ですが、その場合、**File Input Error**（ファイルの形式が無効です）というエラーが発生することがあります（原因不明）。



画像は**自動で 224×224px にリサイズ**されますが、画面上の注意書きのように「アスペクト比が 1:1 ではない画像」は正方形に**トリミング**（＝切り抜き）される点に注意してください。

- (4) 処理が成功すると、次のように当該クラスの学習データの「個数」と「プレビュー」が表示されます。失敗する場合は、「再度、同じ操作を試みる」「ウェブブラウザを再起動する」「別のウェブブラウザを使用してみる（Chrome 推奨）」などで対応してください。



演習 上記と同様の手順で「1」以外の数字（0～9）についても Teachable Machine にアップロードせよ。その際、「img-X.zip」に対するラベル（クラスの名前）を「Class X」のように設定すること。例えば「img-7.zip」には「Class 7」を設定すること。0～9 の数字についてアップロードが完了したら「**モデルをトレーニングする**」のボタンを押下してモデルの学習（トレーニング）を実行すること。



演習 Teachable Machine の「トレーニング」のボックスの「詳細」を展開し、学習に関する 3 つのハイパーパラメータについての説明を確認せよ (ボックス内の ② マークにカーソルを合わせると説明が表示される)。説明文に不明な用語があれば、生成 AI などを利用して解決すること。


- (1) **エポック** (Epoch) (2) **バッチサイズ** (Batch Size) (3) **学習率** (Learning Rate)

Teachable Machine : 画像ファイルを使用した学習②

モデルの学習 (トレーニング) が完了したら (カメラ画像ではなく) **任意の画像ファイル** を与えて **学習済みモデルの性能を評価** します。右端の「プレビュー」のボックスの項目 ❶ を「WebCam」から「ファイル」に変更してください。その後、教材フォルダの **MNIST-test-data** 内の任意の画像を下図 ❷ の領域にドラッグ&ドロップしてください。この **MNIST-test-data** フォルダにある画像は、**MNIST-training-data** フォルダには存在しない手書き数字の画像 (モデルにとっては完全に未知のデータ) となります。



指定領域に画像をドラッグ&ドロップすると、その画像が各ラベル (**Class 0~Class 9**) に分類される確率 (=0~100%) が表示されます。



Teachable Machine : 学習プロセスを制御するパラメータの設定

ニューラルネットワークの学習プロセスを制御するパラメータ（＝ハイパーパラメータ）として、**エポック（数）、学習率、バッチサイズ**というものがあります。

前回講義で解説したように、ニューラルネットワークにおける「**学習**」とは、**適切な予測や分類ができるようにモデルの「重み係数」と「バイアス」を最適な数値に調整すること**を意味しています。この調整は、一般にランダムに設定された初期値から開始して、誤差逆伝播法などのアルゴリズムに基づく繰り返し計算によって**徐々に値を更新**することで行なわれます。例えば、重み係数 $w_{1,2}^{(3)}$ を初期値 1.2 から開始して、モデル性能が向上する方向（勾配）に向かって $1.1 \rightarrow 1.0 \rightarrow 0.9 \rightarrow 0.8 \dots$ のように少しずつ更新していきます（実際の更新量や方向は一定ではありません）。エポック、学習率、バッチサイズは、このような繰り返し計算の制御、および、値の更新に関するパラメータ（設定値）となります。

補足：エポック、学習率、バッチサイズは、重み係数やバイアスのように学習により直接求められる値（＝モデルパラメータ）ではなく、それらをどのように更新するかを決める設定値であるため、**ハイパーパラメータ**と呼ばれます。

- (1) 重み係数・バイアス：学習によって最適化されるパラメータ（モデルパラメータ）
- (2) エポック・学習率・バッチサイズ：学習の進め方を決めるパラメータ（ハイパーパラメータ）

《プロンプト例》

👉 ニューラルネットワークを使った深層学習の文脈で、パラメータ（重み係数やバイアス）と、ハイパーパラメータ（エポック、学習率、バッチサイズなど）の違いが分かりません。文系の高校2年生でもイメージできるように、身近なたとえを使って解説してください。

ハイパーパラメータ：エポック

エポック（Epoch、エポック数）とは「与えられた学習用データセットを使って、何週の学習をするか？」を設定するハイパーパラメータになります。人間が **1 冊の問題集を使って何周も練習するように**、機械学習でも同じデータセットを何度も繰り返し用いて学習を行います。例えば、エポック数を 50 に設定した場合、そのデータセットを用いた学習を（ ）回繰り返すことを意味します。

エポック数が少ない場合、学習が不十分なまま、すなわち重みやバイアスが十分に最適化されないまま学習が打ち切られてしまうため、モデルの性能は低くなります。ただし、学習は短時間で完了します。一方で、エポック数を多く設定すると、学習には時間がかかるものの、基本的にはモデル性能の向上が期待できます。しかし、過度に大きなエポック数を設定すると（ ）：Overfitting）という現象により**汎化性能**（Generalization Performance）が低下し、その結果としてモデルの性能が悪化します。

《プロンプト例》

👉 機械学習における「過学習」と「汎化性能（汎化）」について、初学者向けに丁寧に解説してください。イメージしやすいように、テスト勉強や部活動などの身近なたとえを交えながら説明してください。

ハイパーパラメータ：学習率

学習率 (Learning Rate) とは「重み」や「バイアス」の () に関わるハイパーパラメータになります。学習率を高く設定すると、例えば、重み係数 $w_{1,2}^{(3)}$ について $1.2 \rightarrow 1.0 \rightarrow 0.8 \rightarrow 0.6$ のように大きな刻み幅で更新されるようになります。逆に学習率が低いと $1.2 \rightarrow 1.15 \rightarrow 1.1 \rightarrow 1.05 \rightarrow 1.0$ のように小刻みに更新されるようになります。

学習率が低いと結果的に学習進行が遅くなるため、十分に学習するためにはエポック数を多く設定する必要があります。一方で、学習率が高いと学習が速く進むため、エポック数は少なく済みます (= 学習にかかる時間が短くなります)。しかし、更新幅が大きいことで**最適な値を飛び越えてしまい**、最適値に収束しないというリスクが生じます。例えば、 $w_{1,2}^{(3)}$ の最適値が「0.5」のときに、 $0.8 \rightarrow 0.6 \rightarrow 0.4 \rightarrow 0.6 \rightarrow 0.4 \dots$ のように収束せずに振動してしまう可能性があります。

《プロンプト例》

👉 ニューラルネットワークの学習フェーズのハイパーパラメータである「学習率」の設定のポイントについて、初学者向けに丁寧に解説して下さい。イメージしやすいように身近な例えを用いた直感的な説明をお願いします。

ハイパーパラメータ：バッチサイズ

バッチサイズ (Batch Size) とは、一度の学習計算 * に使用するデータ数を設定するハイパーパラメータになります。先の演習では、学習用データセットとして各クラスにつき 50 個のデータを Teachable Machine にアップロードしました。しかし、Teachable Machine では、これらすべてが学習に使用されるわけではなく **85%だけが学習データに使用されます**。そして、**残りの 15%は、あえて学習には使用せず、学習過程における** () に使用されます。つまり、各クラスにつき $50 \times 0.85 = 42$ 個の画像だけが実際の学習に使われます。しかし、その $42 \times 10 \equiv 420$ 個のデータも全てを同時に使うわけではなく、() という単位に**分割**して学習に使います。1 つのバッチに含めるデータ数 (= 一度に同時処理するデータ数) を指定するのがバッチサイズとなります。

バッチサイズを小さくすることで、**メモリ使用量が抑えられ、また重みとバイアスの更新も頻繁に行われるというメリット**がありますが、その分、更新のばらつきが大きくなり、学習が不安定になることがあります。一方、バッチサイズを大きくすると、学習は安定しやすくなりますが、メモリ使用量が増加し、更新頻度が下がるという特徴があります。

以上のように、エポック (数)、学習率、バッチサイズのいずれも適切な設定が求められる重要なパラメータとなります (大き過ぎても、小さ過ぎても学習プロセスや最終的なモデル性能に悪影響を与えるパラメータとなります)。また「**学習率を低く設定するときは、エポック数を多く設定する必要がある**」のように相互に影響を与え合うパラメータであり、独立して最適値が決められないものとなっています。

* 重みやバイアスなどのモデルパラメータの更新処理

定着確認 深層学習における「エポック数」とは何か。最も適切なものを記号で答えよ。

- ① モデルの学習が完了するまでの時間
- ② ニューラルネットワークの中間層の数
- ③ 与えられたデータセットを学習に使用する回数
- ④ 学習率を設定するパラメータ

定着確認 深層学習において「学習率」を高く設定することで生じる影響はどれか。最も適切なものを記号で答えよ。

- ① 重み係数やバイアスの更新が小刻みになる
- ② 重み係数やバイアスの最適値を飛び越えやすくなる
- ③ 学習におけるメモリ使用量が増加する
- ④ データのバッチ処理速度が向上する

定着確認 深層学習における「汎化性能」に関して誤った説明はどれか。記号で 1 つ答えよ。

- ① 汎化性能は、学習におけるエポック数が多ければ多いほど向上し、学習データに対する精度が高くなるほど未知のデータに対しても優れた精度が得られるという前提に基づいた指標である。
- ② 汎化性能は、学習データに対するモデルの過学習を回避して、未知のデータに対して高い精度の予測や分類ができるかを表した指標である。
- ③ 汎化性能は、学習用データセットから学習した特徴が、検証用データセットにおいても同様に有効であるという前提に基づいており、汎化性能が高いとは、検証用データに対する予測精度が高いことを意味する。
- ④ 汎化性能は、モデルが未知のデータに対してどれだけ適切に予測や分類を行えるかを示す指標であり、主に学習用データセットの多様性に依存する。

定着確認 深層学習における「過学習」について正しい説明はどれか。最も適切なものを記号で答えよ。

- ① 主にエポック数が過剰に多いときに過学習が生じやすい
- ② 主に学習率が高いときに過学習が生じやすい
- ③ 主にバッチサイズが大きいときに過学習が生じやすい
- ④ 主に学習データが多いときに過学習が生じやすい

定着確認 深層学習における「過学習」について正しい説明はどれか。最も適切なものを記号で答えよ。

- ① 過学習が起きたモデルは、学習用データに対する精度が非常に高く、検証用データに対する精度が低い。
- ② 過学習が起きたモデルは、学習用データに対する精度が低く、検証用データに対する精度も低い。
- ③ 過学習が起きたモデルは、学習用データに対する精度が非常に高く、検証用データに対する精度も非常に高い。
- ④ 過学習が起きたモデルは、学習用データに対する精度が低く、検証用データに対する精度が非常に高い。

定着確認 深層学習における「汎化性能」の説明に関して適切なものはどれか。記号で答えよ。

- ① 学習に使わなかった検証用データに対しても精度の高い予測ができる性能
- ② 学習に使用したデータに対して高い精度を示す性能
- ③ 異常な学習データの存在を検出して学習から除外する性能
- ④ 少量の学習データからでも効率よく学習をする性能

定着確認 深層学習における「エポック数」と「学習率」の設定に関して適切なものはどれか。記号で答えよ。

- ① 学習率を低く設定するときは、一般にエポック数を少なく設定する。
- ② 学習率を低く設定するときは、一般にエポック数を多く設定する。

定着確認 深層学習における「汎化性能」の読み仮名を答えよ。

定着確認 深層学習において「汎化性能」を英語で何というか答えよ。

定着確認 深層学習において「過学習」を英語で何というか答えよ。

Teachable Machine：モデルの性能評価

学習済みのモデルに対しては、未知のデータ（例えば **MNIST-test-data** フォルダ内の画像）を与えて、その出力を確認することで、個々のデータに対する分類確率（確信度）を評価することができました。

一方で、俯瞰的かつ総合的に性能評価したいときは

- ・ **正解率**（Accuracy）や**再現率**（Recall）
- ・ **混同行列**（Confusion Matrix）
- ・ **損失**（Loss）

といった指標を用います。これらの指標は Teachable Machine の「トレーニング」のボックスの「**舞台裏**」から確認することができます。



学習済みモデルの性能評価：正解率（Accuracy）と再現率（Recall）

正解率（Accuracy）とは「全クラスを合わせたデータ全体に対してどれだけ正しく分類できたかを表す指標」であり、**再現率（Recall）**は「クラスごとに、各クラスのデータに対してどれだけ正しく分類できたかを表す指標」を表す指標になります。整理すると、次のようになります。

- ・ 正解率（Accuracy）：すべてのクラスを含めた全体の分類精度
- ・ 再現率（Recall）：クラスごとの分類精度

Teachable Machine では、舞台裏のパネルのなかの「**クラスごとの精度**」という項目から再現率が確認できます。「**クラスごとに精度を計算**」のボタンを押下すると、以下のようにクラスごとの**再現率**（0.00～1.00）が表示されます。※画面では **ACCURACY**（正解率）と表示されますが「**RECALL**（再現率）」が適切な表現となります。



CLASS	ACCURACY	# SAMPLES
Class 1	1.00	8
Class 2	1.00	8
Class 3	1.00	8
Class 4	1.00	8
Class 5	0.88	8
Class 6	1.00	8
Class 7	1.00	8
Class 8	1.00	8
Class 9	0.88	8
Class 0	1.00	8

ここでの**再現率**（＝クラス別正解率）とは、各クラスのデータのうち、学習には使わなかった 15% 分の評価用データ（検証用データ、ここでは $50 \times 0.15 \approx 8$ 個）に対して、学習済みモデルが「**どれだけ正しく分類できたかを表す割合**」となります。より正確に言えば「**正解ラベルが「X」であるデータが、正しく「X」に分類された割合**」を意味します。例えば、上図では Class 5 の Accuracy が 0.88 となっていますが、これは 正解ラベルが「5」である 8 個のデータのうち、7 個を正しく「5」として分類できた ということを意味しています。

一方、**正解率**（＝全体正解率）とは、評価用データ全体に対する正解数の割合となります。上記の例で言えば、10 クラス $\times$ 8 個 $= 80$ 個の評価用データのうち、Class 5 と 9 での誤分類 2 個を除いた 78 個が正しく分類できているため、正解率（Accuracy）は $78/80 = 0.975$ となります。

《プロンプト例》

- 👉 機械学習における分類タスクにおいて、正解率（Accuracy）や再現率（Recall）の違いが分かりません。MNISTを例に違いが分かるように説明してください。

なお、再現率は、正解率とは異なり、**クラスごとの得意・不得意を把握するために重要な指標**となります。
特定のクラスの再現率が極端に低い場合、そのクラスの学習データには次のような問題が考えられます。

- (1) データ数が不足している
- (2) 他のクラスと見た目が似ており、区別が難しい
- (3) 学習データのバリエーションが不足している

このような場合には、そのクラスのデータを追加・整理して再学習を行うことで、モデル全体の性能向上が期待できます。

定着確認 機械学習の文脈において「正解率」を表す語はどれか。最も適切なものを記号で答えよ。


- ① Precision ② Recall ③ Accuracy ④ F1-Score ⑤ Loss ⑥ Confusion

定着確認 機械学習の文脈において「再現率」を表す語はどれか。最も適切なものを記号で答えよ。

- ① Precision ② Recall ③ Accuracy ④ F1-Score ⑤ Loss ⑥ Confusion

学習済みモデルの性能評価：混同行列 (Confusion Matrix)

混同行列 (Confusion Matrix) は、クラスごとの分類結果を**さらに詳細に分析するための表**であり、以下のように行列形式で可視化した指標となります。



例えば、図中で赤枠に囲まれた部分は「正解ラベルが「5」のデータについて、誤って「7」と分類されたものが1件あった」ことを示しています。このように、混同行列を参照することで、単なる再現率だけでは分からない**誤分類の内訳**を把握することができます。特に、以下のような観点での分析が重要となります。

(1) どのクラス同士が混同されやすいか

→ 例：「1」と「7」のように見た目が似ているクラスは誤分類が増えやすい

(2) 特定のクラスだけ極端に誤分類が多くないか

→ データ不足や特徴の曖昧さが疑われる

(3) 誤分類の偏りがないか

→ あるクラスに分類されやすい（＝モデルのバイアス）が存在する可能性

また、混同行列は、**適合率**（Precision）や**F 値**（F Score）といった、より詳細な評価指標を計算するための基礎データにもなります。したがって、モデルの性能を多角的に評価するうえで非常に重要な役割を持っています。なお、図中の「Prediction」は、機械学習の文脈では（学習済みモデルからの）**予測**という意味になります。

《プロンプト例》

👉 機械学習の分類タスクにおける「再現率（Recall）」「適合率（Precision）」「F値（F Score）」について、文系の高校2年生でも「なるほど」と思えるように、身近なたとえ話を用いて解説してください。

学習済みモデルの性能評価：損失（Loss）

多クラス分類タスクでは、与えられた入力に対して、各クラスに属する確率（確信度）が出力されます。そして、そのなかで最も確率が高いクラスが予測結果として選択されます。ここで重要なのは、予測結果には「**確率**」という**連続的な情報が含まれている点**です。例えば、正しく分類できた場合でも、その確率は必ずしも 100%とは限らず、数十%程度にとどまることもあります。一方で、誤分類であっても「**まったく見当違いの予測**」から「**正解に非常に近い惜しい予測**」まで、さまざまなケースが存在します。


しかし、正解率は、予測が正しいか誤っているかを 0 か 1 かでしか評価しない指標であるため、このような「確信度の違い」や「誤りの程度」を反映することができません。そこで、学習においては、正解と予測の差異（乖離度）を定量的に評価するために**損失関数**（Loss Function）という指標が用いられます。多クラス分類においては、一般に「**交差エントロピー誤差**」が損失関数として採用されます。

損失関数の出力値は「Loss」と呼ばれ、値が 0.0 に近いほど理想的な状態であり、値が大きくなるほど、予測された確率分布が正解ラベルから大きく乖離していることを意味します。すなわち、Accuracy は「当たったかどうか」だけを見る指標であるのに対し、Loss は「どれくらい自信をもって当てたか／外したか」まで評価する指標となります。

👉 機械学習における損失関数である「交差エントロピー誤差」について初学者向けに解説してください。MNISTデータセットを用いた手書き数字の多クラス分類を具体例に用いて解説してください。また、なぜ確率に対して対数を取るのかという理論的・直感的な理由も解説してください。

Teachable Machine の「舞台裏」の「**エポックごとの損失**」の項目では、学習に使用した 85% のデータに対する損失を **loss** (青線) として、学習に使用しない 15% の評価用データ (検証用データ) に対する損失を **test loss** (橙線) としてグラフが表示されます。このグラフから、学習フェーズでのエポックの進行とともに、どのように損失が変化していったかを確認できます。また、**loss** と **test loss** の推移から、次のような一般的な傾向を読み取ることができます。

エポックごとの損失



- (1) **test loss** が一旦、底を打った後に、上昇に転じているときは、過学習が起きている可能性がある。
- (2) 学習の後半においても **loss** や **test loss** が振動しているときは、学習率が高すぎる可能性がある。
- (3) **loss** と **test loss** の両方が改善せずに停滞している場合、学習率が低すぎる可能性がある。また、Teachable Machine では操作・設定できないが、モデルが単純すぎる可能性がある (これは、中間層を増やしたり、中間層のニューロン数を増やすことで改善される可能性がある)。

定着確認 機械学習において、学習用データに対する損失を **Loss**、検証用データに対する損失を **Test Loss** としてエポックごとのグラフを出力した。このグラフに対する考察として一般的に適切と言える考察はどれか。最も適切なものを記号で答えよ。

- ① エポックが進むにつれて、**Loss** が継続的に減少し、**Test Loss** も減少している場合、モデルが学習データに対して良好に学習していることを示し、検証データに対する汎化もうまく行われていると考えられる。
- ② エポックが進むにつれて、**Loss** が減少しているにも関わらず、**Test Loss** が増加している場合、モデルが学習データに対する学習が不十分で、その結果、検証データにもうまく適応していないことを示している。
- ③ **Loss** がゼロに近づくとき、それはモデルの性能が最大となることを意味し、それは **Test Loss** もゼロに近くなることを意味する。
- ④ エポックが進むにつれて、**Loss** が増加することは、モデルがデータから学習している証拠であり、これは望ましい傾向と言える。

定着確認 多値分類タスクにおいて、次のような「混同行列」が得られた。次の各問いに答えよ。

		Prediction			
Class		イヌ	ネコ	タヌキ	オオカミ
	イヌ	89	0	3	8
	ネコ	1	94	4	1
	タヌキ	4	8	82	6
	オオカミ	15	1	5	79

- (1) 正解ラベルが「タヌキ」のデータについて、誤って「オオカミ」に分類されたものは何件か。
- (2) クラス「ネコ」の Recall (%) はいくらか。
- (3) Accuracy (%) はいくらか。
- (4) このモデルを改善するために最も有効と考えられるアプローチはどれか。
 - ① イヌとオオカミの学習用データを増やして再学習する。
 - ② オオカミとネコの学習用データを増やして再学習する。
 - ③ ネコの学習用データを増やして再学習する。
 - ④ ネコとイヌの学習用データを増やして再学習する。

Teachable Machine が極めて少ないデータセットで学習が可能な理由

ここまでの演習では各クラス **50 枚の画像**をデータセットとして使用しました。また、実際に学習に使用される画像は 42 枚（全体の 85%相当）であり、残りの 15%は評価用データ（検証用データ）として用いられることも確認しました。

一般に、1 クラスあたり 50 という画像数は、画像分類のための機械学習に使用するデータ量としては **圧倒的に不足**しています。通常、これだけの枚数で効果的な分類モデルを得ることはできません。しかし、Teachable Machine では、**Fine Tuning** と呼ばれる **転移学習** (Transfer Learning) の技術を用いることで、限られた枚数の画像からでもある程度の性能を持ったモデルを得ることを可能にしています。

Fine Tuning とは**大規模なデータセットで事前に学習された（類似タスク用の）モデル**を基にして、出力層に近い中間層の構成やパラメータ（重みやバイアス）を新しいデータセットに合わせて再訓練する技術を指します。Teachable Machine の「画像プロジェクト」では、比較的低スペックのコンピュータでも高速動作するよう設計された軽量なディープラーニングモデルである MobileNet を基にした Fine Tuning によって、限られた枚数の画像からでも有効なモデルが得られるようになっています。


[MobileNet](#) の詳細については、ウェブや生成 AI で調べてください。

定着確認 Transfer Learning および Fine Tuning に関する説明として誤っているものはどれか。記号で 1 つ答えよ。


- ① Fine Tuning は、Transfer Learning (転移学習) の 1 手法である。
- ② Fine Tuning とは、類似タスクで事前に学習されたモデルを使用し、出力層に近い中間層のパラメータを新しいデータセットに合わせて再訓練する技術である。
- ③ Fine Tuning とは、既存の学習済みモデルに適合するように入力データを変換および調整 (チューニング) する技術である。
- ④ 限られた学習データしか用意できない場合でも、Fine Tuning を利用することで、一定の性能を持ったモデルを得ることが期待できる。

Teachable Machine による「学習済みモデル」のエクスポート①

Teachable Machine で作成した「**学習済みモデル**」は**エクスポート**して外部プロジェクトで再利用することができます。以下は、Teachable Machine で作成した学習済みモデルをエクスポートして **Arduino** (マイコンボード) と組み合わせて「[お菓子仕分け機 \(Tiny Sorter\)](#)」を実装した例となります。



Things not working out? ▼



Align the tiny sorter with your webcam for good classification.




Angle your computer screen to make the ramp steeper or shallower.

出典 : <https://experiments.withgoogle.com/tiny-sorter/view/>


なお、Arduino については、D コースでは 2 年後期に「プログラミング基礎」、I コースでは 2 年前期に「マイクロコンピュータ」で既に学習済みです。Teachable Machine と各種マイコンを組み合わせたガジェットの設計・製作については以下の動画を参照してください。

→ [マイコンで機械学習モデルを使う@簡単マイコン教室](#)


Teachable Machine から「学習済みモデル」をエクスポートするためには、トレーニングを実行後、プレビューボックスのなかの「**モデルをエクスポートする**」のボタンを押下します。



学習済みモデルをクラウドに配置して（ホストして）、自分以外の人にもウェブブラウザ経由で利用してもらいたい場合は「**モデルをアップロード**」のボタンを押下します。





少し待つと（1～2 分程度）、学習済みモデルがクラウドにアップロードされ、以下のように「**共有可能なリンク (URL)**」が取得可能になります。



例 : <https://teachablemachine.withgoogle.com/models/C3TKwmmYs/>

取得した URL からは、以下のように学習済みモデルを使った「推論フェーズ（予測フェーズ）」を実行できるウェブページにアクセスできます。このウェブページは**スマートフォンにも対応**しており、スマートフォンのカメラからの映像に対してリアルタイムに画像分類／画像認識ができます。




演習 共有可能なリンク（URL）を発行して [qrmaker2](#)（教材フォルダにも URL ショートカット配置）から QR コードに変換せよ。その後、QR コード経由で各自のスマートフォンからウェブページにアクセスして、推論が機能することを確認せよ（ウェブページにアクセスした際、カメラの利用許可などの権限が要求される場合がある）。なお、qrmaker2 については「情報 2」の第 02 回講義で解説済みである。

おまけ：モックアップ画像の生成

Gemini や ChatGPT などの画像生成（画像編集）に対応した生成 AI を利用すれば、スマートフォンや PC などのデバイスに画像をはめ込み合成した「**モックアップ画像**」を簡単に生成することができます。

手順としては、まず、はめ込み合成したい画面のスクリーンショット（スクリーンキャプチャ）を取得します。つづいて、生成 AI に、その画像を添付し「添付した画像をスマートフォンの画面内容として使用し、リアルな iPhone のモックアップ画像を作成してください。」のようにプロンプトを与えます。これにより、右図のようなモックアップ画像を生成することができます。



Teachable Machine による「学習済みモデル」のエクスポート②

⚠ ⚠ ⚠ このトピックは主に知能情報コース向けの内容となります ⚠ ⚠ ⚠


Teachable Machine の裏側では TensorFlow.js というライブラリを使った JavaScript プログラムが動作しています。Teachable Machine で作成された「学習済みモデル」は、TensorFlow に対応した形式でダウンロードが可能です。

ダウンロードした TensorFlow 形式のモデルは、自分で作成した各種プログラムに組み込んで使用すること（＝推論フェーズを実行すること）ができます。具体的には、JavaScript、Python、C++、Java、Go、Arduino など、TensorFlow ライブラリをサポートする様々なプログラミング言語で、学習済みモデルを呼び出して利用することができます。




例えば、Teachable Machine で作成した学習済みモデルを PC やスマートフォンを含めてウェブブラウザで動作する JavaScript プログラムに組み込んで使用したい場合、モデルのエクスポートのなかの「Tensorflow.js」のタブから「ダウンロード」のラジオボタンを選択します。


つづけて「モデルをダウンロード」をクリックすると「tm-my-image-model.zip」がダウンロードされます。この ZIP ファイルを展開すると「metadata.json」「model.json」「weights.bin」の 3 ファイルが得られるので、これらを my_model と名付けたフォルダに格納します。そして、そのフォルダと同じ階層にサンプルコード（HTML + JavaScript）をコピーした index.html を配置します（下図参照）。



後述の方法でローカル環境においてウェブサーバを立ち上げて `index.html` にアクセスすると、以下のようにカメラからの映像に対して推論フェーズを実行することができます。なお、`index.html` をダブルクリックしてウェブブラウザを開いても **CORS (Cross-Origin Resource Sharing) に関連するセキュリティ制限により実行できない**ため注意してください。



ローカルウェブサーバは、VSCode がインストールされている環境であれば、拡張機能の Live Server を使って立ち上げることができます。



また、Python 3 がインストールされていれば、`index.html` が配置されたフォルダで PowerShell を開き `python -m http.server` コマンドを実行して、ウェブブラウザから <http://localhost:8000> にアクセスすることでも同様に動作確認ができます。

教材フォルダには、**カメラ映像の画像から推論するバージョン** (TM-Demo1)、**画像ファイルから推論するバージョン** (TM-Demo2) の 2 つを配置しています。

おまけ：機械学習で使われる有名な画像データセット

ここまでの演習では、手書き数字を分類するための「MNIST」というデータセットを使用しました。しかし、実際の機械学習では、MNIST 以外にも様々な画像データセットが存在し、**モデルの性能を比較・評価するための「ベンチマーク」**として用いたり、**学習やチュートリアル教材**として使用されたりするなど、目的に応じて使い分けられています。ここでは、それらの一部について紹介します。

(1) **CIFAR-10** 📌 [参考](#)

CIFAR-10（シーファー・テン）は、10 クラス（カテゴリ）からなる画像分類タスク用のデータセットになります。飛行機／自動車／トラック／船／鳥／猫／鹿／犬／カエル／馬の **10 種類の物体**を対象とした、 32×32 ピクセルの**カラー画像**で構成されています。各クラスには、学習用に 5,000 枚、テスト用に 1,000 枚の画像が用意されており、合計 60,000 枚（学習用 50,000 枚＋テスト用 10,000 枚）の画像からなります。

(2) **CIFAR-100** 📌 [参考](#)

CIFAR-100 は、CIFAR-10 の拡張版で **100 クラス**（カテゴリ）からなる画像分類タスク用のデータセットになります。基本的な構成は CIFAR-10 と同様で、 32×32 ピクセルのカラー画像で構成されていますが、より細かいカテゴリに分類されている点が特徴です。

各クラスには、学習用 500 枚、テスト用 100 枚が用意されており、合計 60,000 枚（学習用 50,000 枚＋テスト用 10,000 枚）が収録されています。CIFAR-10 では 1 クラスあたり学習用に 5,000 枚の画像があったのに対し、CIFAR-100 では 500 枚と 1/10 に減っており、さらにクラス数が 10 倍に増えているため、**分類タスクの難易度は格段に高くなります**。

また、100 クラスは 20 の上位カテゴリ（スーパークラス）にまとめられており、階層的な分類構造を持っています。例えば、以下のような対応関係です。

Aquatic mammals（水棲哺乳類）

→ Beaver（ビーバー）、Dolphin（イルカ）、Otter（カワウソ）、Seal（アザラシ）、Whale（クジラ）

Flowers（花）

→ Orchid（ラン）、Poppy（ケシ）、Rose（バラ）、Sunflower（ヒマワリ）、Tulip（チューリップ）

(3) **Fashion-MNIST** 📌 [参考](#)

Fashion-MNIST は、MNIST と同じデータ構造を持ちながら、より実用的な画像分類課題を扱うことを目的として作られたデータセットです。画像は 28×28 ピクセルのグレースケールで、T シャツやズボン、バッグ、靴など、日常的な衣類 10 クラスを収録しています。

データ数も MNIST と同様に、学習用 60,000 枚、テスト用 10,000 枚の合計 70,000 枚で構成されています。MNIST は比較的単純な分類問題であるため、モデルの性能差が現れにくいという側面がありますが、Fashion-MNIST ではより複雑な形状や質感の違いを識別する必要があるため、モデルの性能評価に適したデータセットになっています。


(4) ImageNet 参考

ImageNet は、数百万枚規模の画像と数千クラスからなる大規模な画像データセットであり、現代の画像認識技術の発展に大きく貢献した代表的なベンチマークとなっています。特に、画像分類コンペティションである ILSVRC (ImageNet Large Scale Visual Recognition Challenge) では、約 1000 クラス・100 万枚以上の画像を用いた評価が行われ、多くの高性能なニューラルネットワークモデルが提案されてきました。

CIFAR-10 や CIFAR-100 と比較すると、画像サイズやクラス数が大幅に増加しており、より現実的かつ複雑な分類問題に対応しています。そのため計算資源も多く必要となりますが、ImageNet は深層学習モデルの事前学習用データセットとして広く利用されてきており、現在でも基盤的な役割を担っています。

TensorFlow Playground

TensorFlow Playground は、「ニューラルネットワークが入力から出力を生成する仕組み」や「学習の進行に伴って重みやバイアスが最適化されていく過程」を視覚的に理解できるウェブサービスとなっています。日本語訳のバージョンも存在しますが、ここではオリジナル版 (英語版) を利用していきます。



ウェブブラウザ (Chrome 推奨) から以下の URL にアクセスしてください。

 <https://playground.tensorflow.org/#seed=0.6>

※ 解説と実画面を合わせるため、URL に **#seed=0.6** を含めることを忘れないでください。また、実際にアクセスすると # 以降の文字列が **#activation=...** のように書き換わりますが問題ありません。

この TensorFlow Playground は、 x_1 と x_2 の 2 つの特徴量 (入力) を用いて、**青** と **橙 (オレンジ)** の 2

つのカテゴリに分類する**二値分類タスク**を、MLP (Multi-Layer Perceptron) により実行します。例えば、


- ・ 特徴量 $\mathbf{x} = (x_1, x_2) = (0.9, -1.5)$ を与えた場合は「青」
- ・ 特徴量 $\mathbf{x} = (x_1, x_2) = (-3.1, 3.2)$ を与えた場合は「橙」

と正しく分類されるようニューラルネットワークを構成・学習させることが目的です。

TensorFlow Playground : OUTPUT 領域

TensorFlow Playground の画面右側にある **OUTPUT 領域**に表示される情報の意味を確認していきます。中央の座標平面は**横軸**を x_1 、**縦軸**を x_2 としたものであり、そこにプロットされた青丸●および橙丸●の点は、**学習用データセット**の各データポイント（特徴量+正解ラベル）を表しています。

例えば、下図のように特徴量 $\mathbf{x} = (x_1, x_2) = (1.5, -0.8)$ のデータは、正解ラベルが「青」のデータであることを意味します。




また、背景のグラデーションは、ニューラルネットワークの出力関数 $f(x_1, x_2)$ の出力値（連続量）を表したものであり、色の違いは出力値の大小を示しています。凡例により、-1.0 が濃い橙色、1.0 が濃い青色に対応していることが確認できます。「**Discretize output**」にチェックを入れると、出力値は 0.0 を閾値として離散化され、つまり、0.0 未満は-1.0（橙色）、0.0 以上は 1.0（青色）に二値化されて表示されます。

このとき、**丸印で示される学習データ**と、**背景色で示されるニューラルネットワークの出力に基づく分類予測の「色」**が一致していれば、そのデータは正しく分類されていることを意味します。

定着確認 TensorFlow Playground の OUTPUT 領域に右図のような画面が表示されているとする。表示設定は以下の通りである。

- ・ Show test data : オフ
- ・ Discretize output : オン

図中の **①**、**②**、**③** で示されたデータポイントについて、次の問いに答えよ。



- (1) 学習用データセットに属するデータポイントは、**①**～**③**のうちどれか。該当するものを全て答えよ。
- (2) **①**の正解ラベルは () であり、予測ラベル(モデルの出力に基づく分類結果)は () である。括弧にあてはまる色(青 or 橙)を答えよ。
- (3) **③**の正解ラベルは () であり、予測ラベルは () である。括弧にあてはまる色(青 or 橙)を答えよ。
- (4) 適切な分類予測ができているデータポイントは、**①**～**③**のうちどれか。該当するものを全て答えよ。


初期状態(=重み係数やバイアスが最適化されていない状態)では、**約半数で分類に失敗していることが分かります**。「学習データ(=トレーニングデータ)をどの程度うまく分類できているか」を定量的に表現したものが、画面上部に表示されている **Training loss** の数値になります。現状で 0.528 であることが確認できるはずです。日本語では「損失」や「損失関数値」と呼ばれ、この値が小さいほど、予測結果が正解ラベルに近いことを意味します。ただし、これは**単なる正解率ではなく、予測確率のずれも含めて評価している指標**である点に注意してください。

また、Training loss の上部に表示される **Test loss** は、**検証データ(テストデータ)に対する損失関数の値**を示しています。検証データは、学習には用いられないデータであり、ニューラルネットワークにとっては未知のデータとなります。一般に、このような未知データに対してどの程度適切に予測できるか(=汎化性能)が、モデルの実用的な性能を評価する上で重要となります。そのため、Training loss だけを小さくするのではなく、Test loss も同様に小さく保つことが重要です(Training loss のみが小さく、Test loss が大きい場合は過学習が疑われます)。


なお、画面表示下部の **Show test data** にチェックを入れると検証データが可視化されます。

TensorFlow Playground : HIDDEN LAYERS 領域

次に、画面中央の **HIDDEN LAYERS** 領域に表示されている情報を確認していきます。層と層のニューロンを接続している線（以降、**エッジ**と呼称）にカーソルを合わせると「重み係数」を確認することができます。さらに、エッジをクリックすると「重み」を手動で設定できます。ただし、**マウスを移動するとフォーカスが外れてしまうので、キーボードを使って「重み」を変更してください。** **↑↓**のキーでも 1.0 刻みで重みを変更可能です。重みを変更すると、その結果が **OUTPUT** 領域にリアルタイムに反映されることを確認してください。正の重みが付いているエッジは青色、負の重みが付いているエッジは橙色で表示されます。また、絶対値が大きいとエッジは太く表示されます。




中間層（隠れ層）を構成しているニューロンの左下にカーソルを合わせると「**バイアス**」の大きさを確認することができます。「重み」と同様に手動で調整ができるようになっています。



活性化関数については、画面上部に表示される **Activation** の項目から設定できます。初期値は Tanh (Hyperbolic Tangent Function : 双曲線正接関数) となっています。ここでは現在の主流である「**ReLU 関数**」に変更しておきます。


Epoch	Learning rate	Activation	Regularization	Regularization rate	Problem type
000,000	0.03	ReLU	None	0	Classification

各中間層を構成するニューロンの数や、中間層の数を変更したい場合は、「**+**」「**-**」のアイコンをクリックします。




また、特徴量として x_1 と x_2 以外（例えば x_1^2 や x_1x_2 、 $\sin(x_1)$ など）を使用したい場合は、当該のボックスをクリックします。再度クリックするとグレーアウトして無効化されます。

まずは x_1 と x_2 だけを特徴量として有効化しておいてください。



TensorFlow Playground : ニューロンの出力値の表現

各層を構成しているニューロンを表す**グラデーション付きの四角形**は、下図のようにニューロンの**出力値**を「色」として**可視化したもの**となります。具体的には、四角形の左下隅を $(x_1, x_2) = (-6, -6)$ 、右上隅を $(x_1, x_2) = (+6, +6)$ という入力に対応させ、 (x_1, x_2) が入力層に与えられたときの各ニューロンの**出力値**を「色」として**表現したもの**になります。



TensorFlow Playground : 学習①

Test loss が 0.0 に近づくようにニューラルネットワークの学習をしていきます。画面上部の再生マーク「▶」をクリックします。可視化された OUTPUT 領域、Training loss、Test loss に着目しながら学習が進む様子について確認してください。なお、Teachable Machine ではエポック数を指定して学習しましたが、TensorFlow Playground では手動で停止しない限りは永遠に学習が続きます。下図の①をクリックすると学習がリセットされ、②をクリックすると 1 エポックずつ学習が進みます。



ここでのポイントは、限られた層数と限られたニューロン数で Test loss を如何に 0.0 に近づけられるか、ということになります。基本的に層数とニューロン数を多くすれば多くするほど、あるいは x_1^2 や $\sin(x)$ などの特徴量を導入すれば比較的簡単に Test loss を下げることはできます。

定着確認 深層学習において損失関数の出力値 L の一般的な範囲はどれか。最も適切なものを記号で答えよ。

- ① $-1.0 \leq L \leq 1.0$ ② $0.0 \leq L$ ③ $0.0 \leq L \leq 1.0$ ④ $L \leq 0.0$

TensorFlow Playground : 学習②

難易度の高い分類問題に切り替えます。画面左側の **DATA 領域** から「渦巻型」になっているデータセットを選択します。また、Noise も 30 に設定します。Noise はデータに対して「ばらつき」を与える設定値になります。画面下部に表示される「**REGENERATE**」をクリックするとデータが再生成されます。

OUTPUT 領域の **Show test data** のチェックボックスを ON にして、検証データ（テストデータ）の分布についても確認してください。

データの準備が整ったら**モデルの調整**（層数とニューロン数の変更に加え、学習率や活性化関数の変更を含む）と**学習**を繰り返して Test loss が **0.1** 未満になるように試行錯誤をしてください（なお、ここでは特徴量として x_1 と x_2 だけを使用してください）。できるだけシンプルな構造、かつ、Test loss が安定するような（上下に振動しないような）モデルにすることが目的です。




補足：非線形活性化関数の役割

第 04 回講義の p.123-124 では**活性化関数（Activation Function）の役割と必要性**について以下のよう

に説明しました。

活性化関数（アクティベーション関数）をニューロンの出力値に用いる本質的な意味は（出力値を 0.0 から 1.0 にスケールすることではなく）ニューラルネットワークに非線形性を持たせることにあります。この非線形性によって、モデルはより複雑な予測や分類を可能としています。

これは TensorFlow Playground を使って視覚的に確認することができます。TensorFlow Playground では、画面上部の **Activation**（活性化関数）の項目で「**Linear（線形）**」、すなわち、活性化関数に $f(x) = x$ を設定することができます。この設定をすると、以下の図のように多数のニューロンから構成される中間層を多く設けても、中間層を持たない単層のニューラルネットワーク相当の分類しかできなくなります。実際に、Activation を Linear に設定してその挙動について確認してみてください。



課題③ 機械学習を利用した画像分類器の作成

[Teachable Machine](#) の画像プロジェクト（標準の画像モデル）を利用して、224 × 224 px のカラー画像（写真）から「**イヌ**」「**ネコ**」「**タヌキ**」「**キツネ**」「**その他の動物** *」を分類する学習済みモデルを作成し、それをエクスポートした**共有リンク** (<https://teachablemachine.withgoogle.com/models/...>) を各教員が指示する位置に提出してください。

なお、コースにより共有リンク（URL）の提出先（Google Classroom／Moodle／Teams／OneDrive／W フォルダ／個人ポートフォリオ／その他）が異なるので注意してください。**提出期限は第 07 回講義の前日 13 時**とします。

- (1) 教員が用意したテスト画像（＝課題③の評価後に公開、事前非公開）に対するモデルの**正解率（Accuracy）**に応じて **10 点満点で評価します**。つまり、高精度な分類モデルを作成するほど高評価となります。



- (2) クラスの名称（ラベル）は、上から順番に「**イヌ**」「**ネコ**」「**タヌキ**」「**キツネ**」「**その他の動物**」のように設定してください。指示とは異なるラベルや順序となっている場合は、減点となります。
- (3) 最低 90 分以上の時間をかけて取り組んでください（主に学習用データセットの収集・前処理）。
- (4) 提出者本人以外が作成した**共有リンク（URL）**を提出した場合は「不正行為」とします。提供者も含めて 0 点評価とし、担任ならびに所属コースの教員に不正行為を共有・連絡します。
- (5) 担当教員に事前相談することなく、提出期限から 168 時間（＝1 週間・7 日間）を超過して提出されたもの（再提出を含む）は、未提出と同じ 0 点評価とします。
- (6) 課題の採点後は、修正版の再提出・追提出があっても原則として再評価はしません。

この課題では、機械学習を使った画像分類そのものはウェブサービスを使って簡単に実行できるようになっているものの、学習フェーズに必要なデータ（画像）を効率よく準備・前処理するためには、相応の工夫と労力が必要なことを体験的に知ることにも目的としています。

* 陸上生活をする哺乳類を想定してください。

大学入学共通テスト「情報」に挑戦 ⑤

大学入学共通テスト（＝皆さんと同学年の高校 3 年生が受験することになる試験）の「情報」からの抜粋です。今回は、読解力と論理的思考力（情報整理能力）が問われる内容となっています。

2025 年度 第 2 問 次の問い（A・B）に答えよ。

A 高校生の Y さんは、職業体験のため全国チェーンの総合スーパーマーケット「LikeWing」駒谷南店を訪れている。レジを担当した Y さんと店長の会話を読み、後の問い（問 1～4）に答えよ。

Y さん：レシートにはたくさんの情報が印字されていますね（図 1）。このレシートには「ポイント会員 ID」が載っていますが、ポイントカードは店側にとってどんなよいことがあるのですか？

店 長：LikeWing では、ポイントカードを作成する際に、お客様の名前、性別、生年の三つの属性情報をポイント会員情報として登録してもらっています。そして、**[A] ポイント会員情報とレシートに印字されている情報を組み合わせて分析すること**で販売促進につなげています。

Y さん：それらの情報には大切な情報も多いですね。どう管理されているのですか？

店 長：はい。ポイント会員情報とレシートに印字されている情報は、LikeWing の本部の情報システムで一括して管理しています。**[B] 本部、各店舗、商品を製造するメーカー、商品を店舗に配送する配送センターの間で情報をやり取り**していて、商品は本部が一括して発注し、配送の指示を出します。

Y さん：LikeWing のネットショッピングサイトは有名ですね。そのネットショッピングサイトと、この情報システムはつながっているのですか？

店 長：今まさに、連携を検討しているところです。これから **[C] 連携するメリット**は多くあります。

LikeWing
駒谷南店
登録番号:T999999999999999
電話:0XX-XXX-XXX 店コード:3333
AAA県AAA町AA1-1
2025年1月xx日(月) 17:55
レジ#2 2001 責:渡辺

①レジの番号
②担当店員名
③商品コード, 購入商品名
④購入した商品の個数
⑤購入した商品の合計金額
⑥購入した商品の個数の合計
⑦お預かり合計金額
⑧ポイントカードの利用可能ポイント数

購入日, 曜日
購入時刻
店コード
レジの番号
商品コード, 購入商品名
合計
お預かり合計
お釣
ポイント会員ID
買上ポイント
利用可能ポイント

【領収書】
005011 除菌シート 1個 132
011221 ミック 1個 836
001561 スナック菓子 1個 225軽
合計 ¥1,193
(内消費税等 ¥104)
(10%対象 ¥968)
(内消費税額 ¥88)
(8%対象 ¥225)
(内消費税額 ¥16)
点数 3個
上記領収いたしました
お預かり合計 ¥1,500
お釣 ¥307
軽印は軽減税率対象商品です
ポイント会員ID *****1111
買上ポイント 10P
利用可能ポイント 247P

図 1 レシートの例

問 1 次の文章を読み、空欄【ア】～【ウ】に入れるのに最も適当なものを、図 1 の①～⑧のうちから一つずつ選べ。ただし、空欄【イ】・【ウ】の解答の順序は問わない。

LikeWing 全体での「時間帯ごとの総売上額（消費税込）」の比較を行うには、図 1 の「購入時刻」と【ア】に表されている情報から分析する。また、「曜日別の各商品の購入の状況」を把握するには、図 1 の「購入日、曜日」と【イ】と【ウ】に表されている情報から分析する。

問 2 下線部（A）の分析によって得られない情報として最も適当なものを、次の①～③のうちから一つ選べ。

- ① 顧客が商品を購入した理由。
- ② 同じ顧客に、繰り返し購入される傾向がある商品。
- ③ ある商品を多く購入している顧客の年齢層。
- ④ 年齢や性別の違いによる、来店する時間帯の傾向。

問 3 図 2 は、下線部（B）に示す LikeWing の情報システムにおける主な情報の流れと商品の流れを表している。なお、顧客は必ずポイントカードを提示して商品を購入するものとする。




図 2 LikeWing の情報システムにおける主な情報の流れと商品の流れ

図 2 のなかで、次の I ・ II の情報のそれぞれが必要とされる情報の流れ（図 2 の（あ）～（う））を過不足なく含むものを、後の①～⑥のうちから一つずつ選べ。

I 店コード 【オ】

II ポイント会員 ID 【カ】

- ① あ
- ② い
- ③ う
- ④ あ、い
- ⑤ あ、う
- ⑥ い、う
- ⑦ あ、い、う

問 4 下線部 (C) の連携するメリットとして、次の I ～ III が考えられる。これらを実現するために、後の【条件】あ～うのうち、LikeWing の情報システムに求められる条件はどれか。空欄【キ】～【ケ】のそれぞれについて、【条件】あ～うを過不足なく含むものを、後の解答群のうちから一つずつ選べ。

なお、LikeWing のポイント会員であるか否かにかかわらず、ネットショッピングを利用する顧客は、ネットショッピングのアカウントを作成して、宅配のための自宅の住所を登録するものとする。

連携するメリット	条件
I 顧客がネットショッピングサイトにログインしたときに、現在のポイントカードのポイント数と自宅に近い実店舗の広告チラシが自動的に表示される。	【キ】
II 顧客がネットショッピングで商品を購入しようとするとき、その顧客がポイントカードをよく利用する実店舗のうちで、その商品の在庫がある実店舗の情報が表示される。	【ク】
III 顧客がネットショッピングサイトにログインしたときに、商品の購入傾向が実店舗も含めて類似している他の顧客の購入履歴をもとに、おすすめ商品を画面に表示する。	【ケ】

【条件】

- あ ポイント会員 ID とネットショッピングのアカウントが対応付けられている。
- い ネットショッピングで扱われている商品に実店舗で用いられている商品コードが割り当てられている。
- う 商品コードと店コードから実店舗における商品の在庫数を調べることができる。

【キ】～【ケ】の解答群

- ① あ
- ② い
- ③ う
- ④ あ、い
- ⑤ あ、う
- ⑥ い、う
- ⑦ あ、い、う

模試 次の問いに答えよ。(この問題は、本校の「情報 2」で学習済みの内容となります)

第 1 問 問 1 次の生徒 A と生徒 B の会話文を読み、空欄【ア】～【キ】に入れるのに最も適切なものを、後の解答群のうちから 1 つずつ選べ*。

生徒 A : SNS に投稿するデータって、どうやって保存されているのかな？

生徒 B : それには【ア】が使われているよ。データは【イ】に整理されていて、各【イ】は複数の【ウ】で構成されているんだ。

生徒 A : 【ウ】って、【イ】の列のこと？

生徒 B : そうそう。たとえば、ユーザ情報の【イ】には、名前やメールアドレスなどの【ウ】があるんだ。各行のデータのことを【エ】というんだよ。

生徒 A : なるほど。じゃあ、【ア】を管理するソフトウェアはなんていうの？

生徒 B : それは【オ】だよ。【カ】という言葉を使ってデータの操作をするんだ。

生徒 A : どうやってデータを追加すればいいの？

生徒 B : 【キ】文を使って新しい【エ】を【イ】に追加するんだ。たとえば、【キ】`INSERT INTO user(name, email) VALUES ('太郎', 'taro@example.com')` みたいにね。

生徒 A : わかった！ありがとう。

【ア】の解答群

- ① オペレーティングシステム ② データベース ③ クラウドストレージ ④ 圧縮ファイル

【イ】の解答群

- ① クエリ ② テーブル ③ カラム ④ レコード

【ウ】の解答群

- ① テーブル ② インデックス ③ カラム ④ レコード

【エ】の解答群

- ① テーブル ② カラム ③ ビュー ④ レコード

【オ】の解答群

- ① OS ② IDE ③ DBMS ④ UEFI

【カ】の解答群

- ① HTML ② Java ③ SQL ④ Python

【キ】の解答群

- ① CREATE ② INSERT ③ PUSH ④ ADD

* 【ア】 ②、【イ】 ②、【ウ】 ③、【エ】 ④、【オ】 ③、【カ】 ③、【キ】 ②

授業時間外の学習指示

本科目は学修単位であり、**授業時間以外に 4 時間/週の自学自習が要求される科目**です。講義資料のボリュームも試験の難易度も、それを前提に設計・調整しています。また、授業時間外学習を疎かにすると、本科目のほか、PC を利用する授業や実験実習についていくことが難しくなります。最大限、取り組むように心がけてください。

- (1) この講義ノートを再読・熟読し「不明な用語」「理解が十分ではない用語」についてインターネットや ChatGPT などの生成 AI を利用して解決してください。また、興味関心を持ったトピックについて、ウェブ、生成 AI、YouTube 動画などを利用して知識を広げ、理解を深めてください。
- (2) 講義ノート内の**演習**に再度取り組んでください。演習は、授業時間中に 1 回取り組むだけでは定着しないので注意してください。
- (3) **定着確認**に取り組んでください。なお、**定着確認の解答例は公開しません**。技術者には、自分自身で解の妥当性を検証し、責任を負うことが求められます。その訓練と考えてください（ウェブや生成 AI を活用すれば、短時間で解の妥当性が検証できるので、その手間を惜しまないでください）。
- (4) 課題③に取り組んでください。**提出期限は第 07 回講義の前日 13 時です**。
- (5) 次回授業では、Word の高度な利用、OneDrive と連携した共同編集（校閲機能）などを取り上げます。PBL や卒業研究などの報告書作成で必要となる知識やスキルとなります。予習として以下の動画を視聴しておいてください。予習を通じて予備知識を身につけ、理解できない点や疑問点を明確にしておくことで、授業の効果を最大限に高めることができます。

→ この動画一本で完結！文字揃え全部やります！苦手を克服しよう！（22:07）

<https://www.youtube.com/watch?v=njUA1LrrRkk>

→ WORD「変更履歴」の解説です（14:57）

<https://www.youtube.com/watch?v=XuThitUH8Dk>

次回授業：小テスト実施

次回の授業で**小テスト**を実施します。

スキルチェックシート

情報 1・2 と同様に Microsoft Forms の設問に回答し、自分の ICT・AI 利活用スキルを客観的に把握してください。少なくとも次回授業の前日 12 時までには、初回の回答を終えてください（その後、スキルアップしたら随時更新してください）。

回答のスコアの高低は成績評価に反映しませんが、「回答遅れ」や「未回答」があれば成績評価のなかの「課題（35%）」の項目から減点します。



<https://forms.office.com/r/4CxViBGXj4>